Carl von Ossietzky Universität Oldenburg
Fakultät I
Institut für Sozialwissenschaften
Wintersemester 23/24
Fachbachelor: Sozialwissenschaften

Bachelorarbeit

KI als Research Assistant

Ein Fallbeispiel zur Verwendung von chatGPT bei der qualitativen Inhaltsanalyse

Vorgelegt von: Tim Krabbe
Wilhelmshavener Straße 43, 26452 Sande
Matrikelnr.: 2872187
01794702450, tim.krabbe@uni-oldenburg.de

Betreuender Gutachter: Prof. Dr. Sebastian Schnettler
Zweite Gutachterin: Dr. phil. Catharina Peeck-Ho

Oldenburg, den 28.11.2023

Inhalt

1. Einleitung 2
2. Theorie 5
2.1 Large Language Models (LLMs) 5
2.2 Prompting 6
2.3 Qualitative Inhaltsanalyse 8
2.4 Theoretischer Hintergrund des Studienmaterials: Klimawandelskepsis 9
3. Forschungsstand 11
3.1 ChatGPT in der qualitativen Sozialforschung 11
3.2 ChatGPT für die Generierung von (Programmier-)Code 15
3.3 Limitationen und Risiken von LLMs 15
4. Methode und Daten 18
4.1 Daten 18
4.2 Methodik 19
4.3 Programmierung von GPT-3.5 Turbo und Prompt für die deduktive Kodierung 20
4.4 Erfassung der Leistung von GPT-3.5 Turbo 21
4.5 Programmierung von GPT-3.5 Turbo und Prompt für die induktive Kategorienbildung 23
5. Ergebnisse 24
5.1 Ergebnisse der deduktiven Kodierung 24
5.2 Ergebnisse der induktiven Kategorienbildung 30
5.3 Diskussion der Ergebnisse und Beantwortung der Forschungsfragen 34
5.4 Limitationen der Arbeit 36
6. Fazit und Ausblick 36
7. Literaturverzeichnis 39
8. Versicherung an Eides statt 45

Abb. 1: Genauigkeit der Outputs hinsichtlich der Menge eingelesener Beispiele (Zero-, One- und Few-Shot Learning) verschiedener GPT-Modelle, unterschieden nach Anzahl der inhärenten Parameter/ Größe der Trainingsdaten (Params). (Brown et al. 2023: 4) 7

Abb.2: Krippendorffs Alpha nach Codes, deduktive Inhaltsanalyse mit GPT3.5 Tubro (eigene Darstellung 25

Abb. 3: Durchschnitt von Krippendorffs Alpha je Codergruppe (eigene Darstellung) 26

Abb. 4: Krippendorffs Alpha nach Codes, deduktive Inhaltsanalyse mit GPT3.5 Turbo (eigene Darstellung) 27

Abb. 5: Durchschnitt von Krippendorffs Alpha - Experten und GPT3.5 Turbo nach Temperatur (eigene Darstellung) 28

1. Einleitung

> „The speed and reach of this new technology in all its forms are utterly unprecedented. It has been compared to the introduction of the printing press. But while it took more than fifty years for printed books to become widely available across Europe, ChatGPT reached 100 million users in just two months." (Guterres 2023)

Künstliche Intelligenz ist mit der Veröffentlichung des *Large Language Model* (LLM) ChatGPT durch das Unternehmen OpenAI im November 2022 im Mainstream angekommen, wie auch das Zitat des UN-Generalsekretärs Antonio Guterres belegt. Damit gehen sowohl eine Menge Versprechungen als auch diverse Risiken einher. Die EU geht davon aus, dass Künstliche Intelligenz der europäischen Gesellschaft in den kommenden Jahren Verbesserungen in vielen verschiedenen Domänen bringen wird, wie zum Beispiel im Gesundheitswesen, bei der Produktqualität, Arbeitseffizienz, Treibhausgasemissionen oder Bildung und Forschung (vgl. Artificial intelligence: Threats and opportunities 2023). Als Konsequenz wird künstliche Intelligenz und insbesondere ChatGPT mittlerweile in einer Vielzahl von wissenschaftlichen Artikeln behandelt, um Potentiale, Risken und Anwendungsmöglichkeiten auszuloten, unter anderem auch in den Sozialwissenschaften. Thematisch werden dabei beispielsweise Fragen nach der zukünftigen Rolle von ChatGPT in der Hochschullehre (vgl. Crompton & Burke 2023; Escotet 2023; Glaser 2023; Fauzi 2023), den Potentialen des methodischen Einsatzes in den Sozialwissenschaften (vgl. Bail 2023; Hayes 2023) oder der Bedeutung für das wissenschaftliche Arbeiten im Allgemeinen (vgl. Dergaa et al 2023; Dwivedi et al. 2023) betrachtet. Eine vielversprechende Einsatzmöglichkeit von LLMs wie ChatGPT in den Sozialwissenschaften und auch darüber hinaus ist die qualitative Inhaltsanalyse, womit sich diese Arbeit im Detail beschäftigen wird.

Die Relevanz dieses Themas ergibt sich zum einen aus seiner bereits angesprochenen Aktualität und der schnellen und mehrheitlich positiv bewerteten Annahme und alltäglichen Einbindung der Technologie durch die Gesellschaft (Haque et al. 2022). Zum anderen ergibt sich die Relevanz aus den damit verbundenen, aber noch nicht ausreichend erfassten, angedeuteten Potentialen. Die qualitative Inhaltsanalyse ist eine der zentralen Analysemethoden der qualitativen Sozialforschung (vgl. Flick 2022); Google Scholar zeigt für den Suchbegriff „qualitative content analysis" beispielsweise 5,5 Millionen Einträge. Sie ist jedoch gleichzeitig insbesondere bei großen Datenmengen ausgesprochen arbeitsintensiv, da das gesamte Material gesichtet werden muss, Kategorien und Codes gebildet werden und anschließend auf das Material angewendet werden müssen. Technologien wie LLMs bergen das Potential, diese Aufgaben zu

automatisieren, somit Arbeitszeit und -aufwand einzusparen und die Effizienz in der qualitativen Sozialforschung zu steigern. Die vorliegende Arbeit beschäftigt sich deshalb mit zwei Forschungsfragen:

> **Frage 1:** Inwiefern eignet sich ChatGPT zur deduktiven Kodierung von Textmaterial im Sinne der qualitativen Inhaltsanalyse?
>
> **Frage 2:** Inwiefern eignet sich ChatGPT zur induktiven Kategorienbildung im Sinne der qualitativen Inhaltsanalyse?

Das Ziel dieser Arbeit ist es, die Eignung von ChatGPT als Werkzeug bei der Durchführung einer qualitativen Inhaltsanalyse zu bemessen sowie einen Vorschlag zum Ablauf des dahinterliegenden Arbeitsprozesses zu machen. So soll ein Beitrag zu der aktuellen Debatte bezüglich Verwendung von künstlicher Intelligenz in der wissenschaftlichen Arbeit geleistet werden. Die Leistung ChatGPTs bei der deduktiven Kodierung ist bereits in einigen Studien behandelt worden, wie sich in Kapitel 3.1 zeigen wird, aus diesen gehen jedoch bei gesamtheitlicher Betrachtung keine eindeutigen Ergebnisse hervor (vgl. Gilardi et. al 2023; Törnberg 2023a; Xiao et al. 2023), weshalb hiermit eine Ergänzung dieser Studien angestrebt wird. Währenddessen lässt sich hinsichtlich einer KI-assistierten induktiven Kodierung großer Datenmengen eine Forschungslücke ausmachen (vgl. Xiao et al. 2023: 77), die mit der zweiten Forschungsfrage adressiert werden soll.

Das Datenmaterial, anhand dessen die Forschungsfragen beantwortet werden sollen, besteht aus 947 Redebeiträgen von Abgeordneten des EU-Parlaments der sechsten bis achten Legislaturperioden (2004-2019). Die Akquise der Daten orientiert sich ebenso wie das theoretische Fundament, mit welchem die Inhaltsanalysen durchgeführt werden sollen, an dem Artikel *Scepticisms and beyond? A comprehensive portrait of climate change communication by the far right in the European Parliament* der Autoren Forchtner und Lubarda (2022). Die Daten werden mittels Webscraping systematisch von der Website des Europaparlaments heruntergeladen. Die Wahl dieses Materials bietet sich aus unterschiedlichen Gesichtspunkten an. Erstens besteht ein umfangreiches, theoretisch fundiertes Codebuch, das nach kurzer Aufbereitung zur deduktiven Analyse verwendet werden kann und außerdem als Referenz für die von ChatGPT im Zuge der induktiven Analyse generierten Kategorien dienen kann. Zweitens liegen die einzelnen Redebeiträge in unterschiedlichen europäischen Amtssprachen vor, was die Flexibilität von LLMs bei der Sprachverarbeitung und die damit einhergehenden

Vorteile in der qualitativen Sozialforschung unterstreicht. Und drittens zeigen Wang et al. (2023: 8), dass die Performance von LLMs je nach Thema unterschiedlich ausfallen kann, weshalb es sinnvoll erscheint, ein Thema für die Analyse auszuwählen, welches in der Literatur zu ähnlichen Fragestellungen bisher nicht Teil der Performanceerfassung von ChatGPT gewesen ist und außerdem ein hohes Maß an Aktualität bietet.

Aus diesem Korpus wird ein Sample von 20 zufällig gezogenen Redebeiträgen den Experten und dem Sprachmodell GPT-3.5 Turbo zur deduktiven Kodierung anhand des Codebuchs vorgelegt. Dieses Sprachmodell von OpenAI liegt dem Tool ChatGPT zugrunde, weshalb GPT-3.5 Turbo und ChatGPT in dieser Arbeit synonym verwendet werden. Die Kodierung durch das Sprachmodell geschieht in drei verschiedenen, sogenannten *Temperatureinstellungen*, die für das Modell im Vorfeld ausgewählt werden können und die die Zufälligkeit des Outputs festlegen (siehe Kapitel 2.1), jeweils fünf Mal. So kann mit der Berechnung der Intercoder Reliabilität die Konsistenz des Modells pro Temperatur getestet werden. Anschließend wird je Temperatureinstellung die Intercoder Reliabilität zwischen Modell und Experten berechnet, was eine Einschätzung der Qualität der durch das Modell durchgeführten Kodierung ermöglichen soll. Für die induktive Kategorienbildung wird dieses kleinere Sample ebenso wie ein neues Sample von 50 zufällig ausgewählten Redebeiträgen genutzt, welche erneut ChatGPT vorgelegt werden. Basierend auf beiden Samples wird dann versucht, Kategorien im Sinne einer induktiven Inhaltsanalyse zu generieren, die im Anschluss in einer offenen Diskussion der Ergebnisse und durch den Vergleich mit dem bereits existierenden Codebuch bewertet werden sollen.

Im Folgenden wird zunächst auf den theoretischen Hintergrund dieser Arbeit eingegangen. Hier werden die Funktionsweise von LLMs sowie der Begriff des *Prompting* erklärt, der theoretische Hintergrund der qualitativen Inhaltsanalyse umrissen und letztlich das Konzept der Klimaskepsis erläutert. Anschließend wird der Forschungsstand zu der Verwendung von LLMs in der qualitativen Sozialforschung, insbesondere bei der Inhaltsanalyse, vorgestellt und außerdem relevante Forschungsergebnisse zu ihrer Verwendung in der Wissenschaft allgemein kurz angesprochen. Darauffolgend wird das methodische Vorgehen im Detail dargestellt und die Ergebnisse dieses Vorgehens im anschließenden Kapitel präsentiert. Nach einer Besprechung der Limitationen dieser Arbeit wird sie mit einem Ausblick auf weiterführende Forschungsmöglichkeiten und einem Fazit abgeschlossen.

2. Theorie

2.1 Large Language Models (LLMs)

Die Abkürzung „LLM“ steht für Large Language Model und beschreibt neuronale Sprachmodelle von besonders großem Umfang. LLMs können auf große Mengen an Trainingsdaten zurückgreifen, weshalb sie auch oft (*Pretrained*) *Foundational Models* genannt werden (vgl. Zhou et al. 2023; Paaß & Giesselbach 2023: 3). Sie sind in der Lage, Texte zu „verstehen“ und selbst zu generieren. Ein Beispiel für solche Modelle sind die *Generative Pre-Trained Transformer*-Modelle (GPT) von OpenAI. Diese basieren auf der sogenannten *Transformer*-Architektur. Sie erhält ihren Namen aufgrund ihrer transformierenden Textverarbeitung: Eingabetexte, die sogenannten Prompts, werden zunächst „tokenisiert“ (vgl. Vaswani et al. 2017). Die sogenannte „Tokenisierung“ bezeichnet im Natural Language Processing einen Prozess, in dem Wörter und Wortsequenzen in kleinere Einheiten aufgeteilt werden, die Tokens und Subtokens genannt werden. In den GPT-Modellen wird dafür das sogenannte Byte-Pair Encoding (BPE) genutzt (vgl. Berglund & van der Merwe 2023: 16). Mittels BPE wird ein Vokabular erstellt, welches nicht beziehungsweise nicht komplett aus vollständigen Wörtern, sondern aus unterschiedlich langen Buchstabensequenzen, den Subtokens, besteht, was auch die Verarbeitung von besonders komplexen Wörtern effizient möglich macht (vgl. Sennrich et al. 2016). Das LLM-Modell GPT-2 aus dem Jahr 2019 von OpenAI verfügt beispielsweise über ein Vokabular von 50257 Subtokens, also Buchstabensequenzen, aus denen sich wiederum Tokens und damit Wörter zusammensetzen lassen (vgl. Berglund & van der Merwe 2023: 16).

Die Tokens wiederum werden anschließend an die Tokenisierung des Textes in einen mathematischen Raum eingebettet: Jedes Wort wird in einen Vektor umgewandelt, in diesem mathematischen Raum platziert und mit seinen entsprechenden Koordinaten in diesem Raum versehen. Aus den Koordinaten der einzelnen Tokens einer Eingabe wird eine Trajektorie in diesem Einbettungsraum von Token zu Token schrittweise berechnet, aus welcher sich das Modell sozusagen den Sinn der Eingabe erschließen kann und auf dieselbe Art und Weise eine Antwort generieren kann. Diese Generierung von Antworten erfolgt bei autoregressiven Modellen wie den GPT-Modellen probabilistisch, das heißt, auf Basis der Eingabe und der Trainingsdaten wird die wahrscheinlichste Antwort generiert; auf Basis der vorherigen Tokens einer Sequenz, versucht das Modell den nächsten Token anhand seiner geschätzten Wahrscheinlichkeit auszuwählen (vgl. Kucharavy et al. 2023; Paaß & Giesselbach 2023: 37).

2.2 Prompting

Der Begriff *Prompt* bezeichnet im Kontext von Künstlicher Intelligenz und LLMs eine Texteingabe oder einen Input, den ein Benutzer eines solchen Modells in dieses eingibt und anhand dessen das Modell einen Output generiert. Ein solcher Prompt wird in natürlicher Sprache verfasst und bildet damit den Schnittpunkt von Mensch-Modell-Interaktion. Natürliche Sprache meint dabei schlicht eine Sprache, die natürlich entstanden ist und von ihren Nutzern als natürlicher Teil des Aufwachsens und der Sozialisation erlernt wird (vgl. Lyons 1991: 1). Eine Interaktion zwischen Mensch und Computer, die in natürlicher Sprache stattfindet, ist keine neue Idee, wie Barnett und Ruhsam (1968) mit der Entwicklung eines *Natural Language Programming Systems* zeigen: Ein System, das Laien die Interaktion mit Computern in einfachen, im Vorfeld ausgewählten Wörtern und Sätzen auf Englisch ermöglichen sollte. Genauso ermöglichen Prompts die direkte Kommunikation mit einem LLM, die prinzipiell sogar auf alltagssprachlichem Niveau stattfinden kann und damit eine niedrigschwellige Nutzung ermöglichen kann. Jedoch ist dabei immer zu beachten, dass schon kleine Veränderungen eines Prompts großen Einfluss auf den Output des Modells haben können; ein Problem, das weiterhin bestehen bleibt: „Developing LLMs that are robust to the prompt's style and format remains unsolved, leaving practitioners to design prompts ad-hoc rather than systematically" (Kaddour 2023: 17).

Das Erstellen und Bearbeiten von Prompts wird *Prompt Engineering* genannt. Der Inhalt eines gut strukturierten, instruierenden Prompts kann auf vier Bestandteile aufgeschlüsselt: *Instruction, Context, Input Data* und *Output Indicator* (vgl. DAIR.AI o.D.). Einem Modell müssen also eine Aufgabe, zugehörige kontextuelle Informationen, die zu bearbeiteten Daten und die Beschreibung des gewünschten Output-Formats mitgeteilt werden. Kaddour (2023: 17ff.) unterscheidet außerdem zwischen Single-Turn und Multi-Turn Prompting. Single-Turn Prompting wendet einen einzelnen Prompt an, der iterativ verbessert wird, bis das gewünschte Ergebnis wiedergegeben wird. Als Beispiele für das Single-Turn Prompting nennt Kaddour *In-Context Learning*, *Instruction-Following* und *Chain-of-Thought*, wobei *Instruction-Following* oder *Instruction Fine-Tuning* die besten Ergebnisse zu erreichen scheint (vgl. ebd.: 22; Iyer et al. 2022; Chung et al. 2022). Bei dieser Methode besteht der Prompt aus einer ausformulierten Anweisung sowie einem oder mehreren Beispielen dazu, wie die Antwort des Modells aussehen soll (vgl. Kaddour 2023: 22). Eine bei der Arbeit mit LLMs oft genutzte Technik ist die sogenannte *In-Context Impersonation* (vgl. Salewski et al. 2023;

Kaddour 2023: 19), bei der dem Modell im Prompt vorgegeben wird, den Output so zu formulieren, als wäre er von einer bestimmten Person, in der Regel einem Experten auf dem gefragten Feld, verfasst worden. Die Performance eines Modells scheint von der Anwendung dieser Technik zu profitieren, wobei zu beachten ist, dass die Imitation bestimmter Personen ebenfalls Imitationen der dieser Person inhärenten Biases mit sich bringen kann (vgl. Salewski 2023: 9).

Weiterhin wird bei Prompts zwischen *Zero-*, *One-* und *Few-Shot Learning* unterschieden. Für *Zero-Shot Learning* besteht der Prompt lediglich aus einer normalerweise ausformulierten Aufgabe oder Frage, ohne zusätzliches Beispiel. Beim *One-Shot Learning* hingegen wird für die gesamte Aufgabe ein einzelnes Beispiel im Prompt bereitgestellt, an dem das Modell sich orientieren kann. *Few-Shot Learning* verwendet wiederum eine Mehrzahl von Beispielen. Zu beachten ist jedoch, dass sich die Parameter des Modells nicht ändern; das Modell wird auf diese Weise also nicht trainiert, sondern greift weiterhin auf die im Voraus erlernten Daten zurück (vgl. Paaß & Giesselbach 2023: 141). Gemeinhin scheint *Few-Shot Learning*, gemessen an einer Vielzahl unterschiedlicher Aufgaben, am leistungsstärksten zu sein, wobei für die Beispielanzahl schnell ein oberes Limit erreicht wird, über dem sich die Leistungssteigerung deutlich abschwächt (vgl. Abbildung 1). Die besten Ergebnisse werden außerdem durch eine Kombination mehrerer Beispiele mit einem ausformulierten Prompt erreicht (Brown et al. 2020: 4).

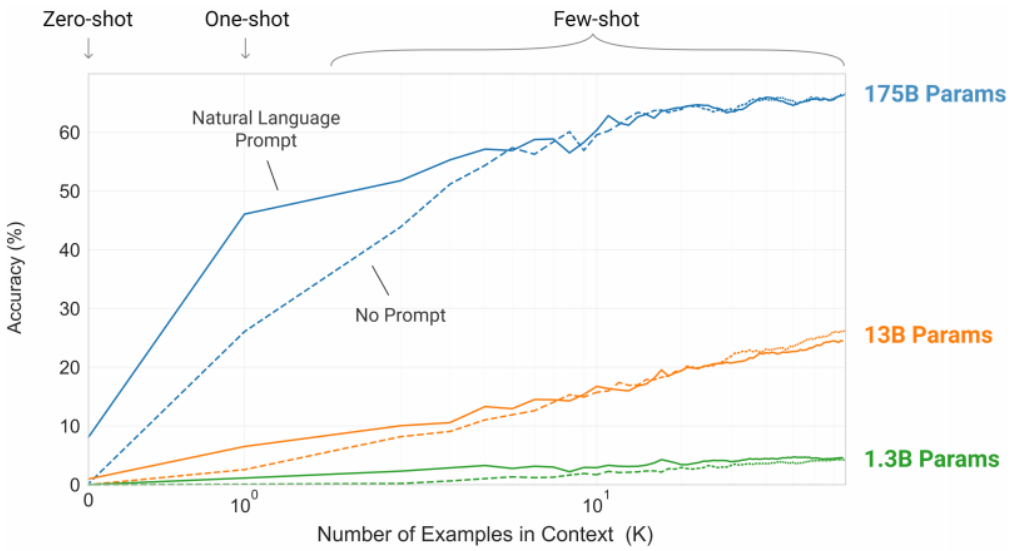

Abb. 1: Genauigkeit der Outputs hinsichtlich der Menge eingelesener Beispiele (Zero-, One- und Few-Shot Learning) verschiedener GPT-Modelle, unterschieden nach Anzahl der inhärenten Parameter/ Größe der Trainingsdaten (Params). (Brown et al. 2023: 4)

2.3 Qualitative Inhaltsanalyse

Die qualitative Inhaltsanalyse ist innerhalb des qualitativen Paradigmas zu verorten. Nach Krauss (2005: 760f.) unterscheidet sich die qualitative Sozialforschung in ihren Grundannahmen von der quantitativen Forschung, da ihr Blickwinkel auf die Welt ein relativistischer und konstruktivistischer ist, in dem keine objektive Realität, sondern viele unterschiedliche individuelle Realitäten existieren. Diese Realitäten seien nicht generalisierbar und nur in ihrem spezifischen Kontext analysierbar. Daraus folgt ein in der Regel eher theoriegenerierender Charakter der qualitativen Sozialforschung, während die quantitative Forschung in der Regel theorietestend vorgeht (vgl. Strübing 2018: 7). Ausgehend von der relativistischen Perspektive der Sozialforschung fällt darüber hinaus der Anspruch auf Objektivität der Forschung weg; anstatt dessen wird die Subjektivität der Forschenden zu einem Teil des Forschungsprozesses und beeinflusst diesen maßgeblich (vgl. Flick 2023: 8). Daten in der qualitativen Sozialforschung liegen oft in Textform vor, beispielsweise als Transkription von Interviews. Eine geläufige Methode, um mit diesen Daten zu arbeiten ist, abgesehen von vielen anderen in der qualitativen Forschung angewandten Methoden, die qualitative Inhaltsanalyse. Schreier definiert die qualitative Inhaltsanalyse folgendermaßen:

> QCA [qualitative content analysis] is a method for describing the meaning of qualitative material in a systematic way. You do this by assigning successive parts of your material to the categories of your coding frame. This frame is at the heart of QCA, and it covers all those meanings that feature in the description and interpretation of your material. (Schreier 2012: 1)

Mayring (2000) unterscheidet zwischen induktiver und deduktiver Kategorienentwicklung. Ersteres geschieht in einer Rückkopplungsschleife, in der zunächst Kategorien theoriegeleitet aus dem Textmaterial heraus entwickelt, anschließend auf ihre Reliabilität überprüft, und dann gegebenenfalls erneut überarbeitet werden, um nach einer weiteren Reliabilitätsprüfung abschließend auf das Material angewendet zu werden (vgl. ebd.: 3f.) Hsieh und Shannon (2005: 1279) beschreiben diesen Ansatz als angebracht, wenn das theoretische Fundament des zu untersuchenden Phänomens nur wenig ausgeprägt ist; der Ansatz dient also dem Ziel der Theoriegenerierung. Letztlich werden anhand des Textes Kategorien und Subkategorien gebildet, die in ein Codebuch überschrieben werden und unter dessen Berücksichtigung das Textmaterial erneut im Detail untersucht wird. Elo und Kyngäs (2007: 111) beschreiben den induktiven Forschungsprozess beginnend mit einer offenen Kodierung, aus der Subkategorien gebildet werden und anschließend unter thematisch übergeordnete Kategorien subsummiert werden, um ein Phänomen zu beschrieben, das Verständnis desselben zu

verbessern und Wissen zu generieren. Darauf folgt der Schritt der Abstraktion, bei dem das auf das untersuchte Phänomen bezogene, neu generierte Wissen so weit wie möglich auf die kontextuelle Thematik generalisiert wird.

Bei der deduktiven Kategorienanwendung hingegen werden die Kategorien nicht anhand des Textmaterials, sondern vor der Arbeit mit dem Material von einer theoretischen Grundlage abgeleitet und erstellt. Auch hier wird die Reliabilität der Kategorien überprüft, woraufhin diese entsprechend überarbeitet werden. Die Kategorien werden in einen Kodierleitfaden oder ein Codebuch übertragen, in dem sich neben den Kategorien auch Definitionen und Beispiele finden und anhand dessen sich die Inhaltsanalyse orientieren soll (vgl. ebd.: 4ff.). Hsieh und Shannon (2005: 1281) nennen dies auch *gerichtete Inhaltsanalyse*. Das Ziel der gerichteten Inhaltsanalyse liegt in der Validierung oder kontextuellen Erweiterung eines theoretischen Rahmens oder einer Theorie; ebenfalls kann diese Form der Analyse zum Testen von Kategorien, Konzepten, Modellen oder Hypothesen dienen (vgl. ebd.; Elo & Kyngäs 2007: 111). Sie ist also nicht immer von demselben theoriegenerierenden Charakter wie der Großteil der qualitativen Sozialforschung. In der Erweiterung und Unterstützung bereits existierender Theorien sehen die Autoren gleichzeitig einen der Vorteile der gerichteten Inhaltsanalyse, genauso wie darin, dass der Ansatz verdeutlicht, dass die Forschenden nicht aus einer naiven Perspektive heraus arbeiten (vgl. ebd.: 1283). Limitationen finden sich hingegen in der Tendenz zur Voreingenommenheit durch das theoretische Grundmaterial, der Gefahr nicht wertfrei Daten zu erheben (beispielsweise in Interviews) und in einer möglicherweise überzogenen Fixierung auf das theoretische Material, was die Perspektive auf andere Kontextfaktoren verschließen könne (vgl. ebd.).

2.4 Theoretischer Hintergrund des Studienmaterials: Klimawandelskepsis

Hinsichtlich des Ziels dieser Arbeit, die Beantwortung der Frage nach der Eignung von ChatGPT für die Anwendung in der qualitativen Inhaltsanalyse, sollte kurz der theoretische Hintergrund des dafür verwendeten Materials erläutert werden. Wie zu einem späteren Zeitpunkt (siehe Kapitel 4.1) im Detail erläutert, ergibt sich das Material aus einem Korpus von Debattenbeiträgen rechtsextremer und -radikaler Abgeordneter des Europaparlaments zur europäischen Klimapolitik sowie aus einem Codebuch, welches Kategorien zur Einordnung von klimawandelskeptischen Aussagen und Einstellungen enthält und auf Beiträgen von Forchtner und Lubarda (2022) und van Rensburg (2015) basiert. Der Begriff der Klimawandelskepsis soll im folgenden Abschnitt erläutert werden.

Van Rensburg (2015) unterscheidet zwischen drei verschiedenen Arten der Klimawandelskepsis, sowohl basierend auf den Inhalten der geäußerten Kritik als auch auf den Einstellungen der entsprechenden Skeptiker. Das, was van Rensburg *Evidence Scepticism* nennt, steht demnach im Zentrum der Theorie und beschreibt jedwede Skepsis hinsichtlich wissenschaftlich gesicherter Fakten zum Klimawandel. Im Detail teilt sich diese Form in eine dreiteilige Trend-Attribution-Impact-Typologie auf und beschreibt die Leugnung eines Erwärmungstrends (*Trend*), die Abstreitung eines menschlichen Einflusses auf denselben (*Attribution*) oder das Herunterspielen des Ausmaßes dieser Erwärmung und ihrer Folgen (*Impact*). *Evidence Scepticism* bildet das Zentrum der Klimawandelskepsis, da die Typologie aus *Trend, Attribution* und *Impact* direkt mit der zentralen Mainstreamhypothese vom anthropogenen Klimawandel korreliert (vgl. ebd.: 3).

Die zweite Form der Klimawandelskepsis nennt van Rensburg *Process Scepticism*, die sich sowohl gegen die Prozesse der wissenschaftlichen Wissensgenerierung als auch gegen die öffentlichen und politischen Entscheidungsprozesse bezüglich des Klimawandels richten. *Process*-Skeptiker kritisieren beispielsweise vermeintliche strukturelle Probleme im wissenschaftlichen Publikationsbetrieb und beim Peer Review, die IPCC-Berichte oder die Abhängigkeit von Computermodellen sowie auch eine vermeintlich übertriebene Berichterstattung der Medien. Weiterhin ist *Process Secpticism* unabhängig von den anderen beiden Formen und kann daher auch von Personen vertreten werden, die die grundlegenden Erkenntnisse zum Klimawandel nicht infrage stellen (vgl. van Rensburg 2015: 4).

Die dritte Form ist nach van Rensburg *Response Scepticism*. Diese Form ist ebenfalls unabhängig von Einstellungen hinsichtlich der Mainstreamhypothese des anthropogenen Klimawandels, da sie sich hauptsächlich auf die politischen Maßnahmen im Zusammenhang mit demselben bezieht, meist auf deren Kosten oder ihre Wirksamkeit. Der Autor unterscheidet hier thematisch zwischen konkreter Kritik an *policy instruments* und Kritik an einem allgemeineren *policy style*. Ihrer wird sich dementsprechend häufig auch von *Impact*-Skeptikern bedient, da mit der Unterschätzung von Klimawandelfolgen das Narrativ von vermeintlich überflüssigen Maßnahmen oft einhergeht (vgl. van Rensburg: 4f.)

Forchtner und Lubarda (2022) bringen diese Theorie nun mit Rechtsextremismus und -radikalität in Verbindung und erweitern van Rensburgs Taxonomie um einige

Unterkategorien. Die Autoren gehen von einer Verbindung von politisch rechten Positionen und klimawandelskeptischen Einstellungen aus, insbesondere bezüglich der politischen Maßnahmen zur Bekämpfung des Klimawandels (vgl. Forchtner & Lubarda 2022: 49) und postulieren ein Übergewicht an *Process* und *Response Scepticism* (vgl. ebd.: 62). Die weitere Erläuterung theoretischer Annahmen der Autoren, wie beispielsweise die Unterscheidung von Rechtsextremismus und -radikalismus, ist für diese Arbeit allerdings nicht zielführend und wird daher nicht weiterverfolgt.

3. Forschungsstand

Obwohl die Forschungsliteratur zu LLMs wie ChatGPT im Laufe des letzten Jahres schnell gewachsen ist, ist der Forschungsstand zur Nutzung von LLMs in der qualitativen Sozialforschung zum aktuellen Zeitpunkt noch nicht sehr ausgeprägt, was trotz der Popularität des Themas schlicht daran liegen dürfte, dass es erst mit der Veröffentlichung von ChatGPT im November 2022 einen breiteren Zugang zu den dafür nötigen Werkzeugen gibt. Ein wissenschaftlicher Konsens über die Eignung und Nutzungsmöglichkeiten von LLMs für Aufgaben in der qualitativen Sozialforschung steht dementsprechend noch aus, weshalb sich in der Literatur diesbezüglich gegensätzliche Ergebnisse und Empfehlungen finden. Weiterhin liegt darin auch begründet, dass ein nicht unerheblicher Teil der hier vorgestellten Literatur über die GPT-Modelle bisher nur als Preprint vorliegt und damit noch keinem Peer-Review unterzogen worden ist.

3.1 ChatGPT in der qualitativen Sozialforschung

Törnberg (2023a) vergleicht beispielsweise die zero-shot Kodierungs-Performance von ChatGPT sowohl mit der von Experten als auch mit der von untrainierten Crowdworkern bei der binären Kodierung von 500 Tweets zum US-Wahlkampf 2020. Der Autor nutzt in seinem Artikel Tweets von US-Senatoren und lässt diese bezüglich ihrer politischen Zugehörigkeit zu einer der beiden US-amerikanischen Parteien kodieren. Die Aufgabe wird von ChatGPT mit unterschiedlichen Einstellungen der *Temperature* durchgeführt, um das Optimum dieser Einstellung für die gestellte Aufgabe zu evaluieren. Die *Temperature* gibt wieder, welcher Grad an Zufälligkeit in der Textgenerierung verfolgt wird und damit, wie „kreativ“ das Modell vorgeht. Sie kann in ChatGPT aktuell die Werte zwischen 0 und 2 annehmen, wobei 0 den geringsten Grad an Zufälligkeit darstellt. Für den Vergleich von Modell und Experten hat der Autor die Inter-Rater Reliability mit Krippendorfs Alpha berechnet. Demnach übertrifft ChatGPT die beiden Vergleichsgruppen in allen Belangen: „The findings suggest that LLMs may already outperform the standard approaches of crowd-workers and expert classifiers,

offering higher accuracy, higher reliability, and lower or equal levels of bias" (Törnberg 2023a: 4).

Gilardi et al. (2023) führen eine ähnliche Studie durch, in der ChatGPT ebenfalls mit der Leistung von Crowdworkern und Experten bei verschiedenen Annotationsaufgaben verglichen wird. Als Material dienen 6183 Tweets in vier Samples. Im Gegensatz zu Törnberg haben die Autoren die Intercoder Reliability von ChatGPT mit sich selbst berechnet, indem die Aufgaben jeweils zweimal pro Temperatureinstellung (0,2 und 1) durchgeführt wurden (vgl.: 3). Letztendlich vergleichen die Autoren die Intercoder Reliability der einzelnen Gruppen mit- und untereinander; dabei übertrifft ChatGPT die Crowdworker wie auch Experten, wobei die höchsten Übereinstimmungen bei einer *Temperature* von 0,2 gemessen wurde (vgl. ebd.: 4). Außerdem erzielt ChatGPT eine gegenüber Crowdworkern um durchschnittlich 25% höhere Treffsicherheit (*Accuracy*) bezüglich korrekter Annotationen verglichen mit dem Goldstandard-Ergebnis der Experten (vgl. ebd.: 3). Tai et al. (2023) kommen bei einer Reliabilitätsanalyse von ChatGPTs Fähigkeit zur deduktiven Kodierung zu ähnlichen Ergebnissen. Die Autoren nutzen ein Sample von drei Interviewausschnitten aus einem für eine frühere Studie erstellten Materialkorpus und wiederholen die Kodierung mit ChatGPT bis zu 160-mal. Zur Überprüfung der Reliabilität errechnen sie einen „large language quotient" (LLMq), "where the total number of positive responses in a set of iterations was divided by the number of iterations for that given set" (vgl. ebd.: 13). Die Ergebnisse legen nahe, dass die Kodierung nach einer ausreichenden Anzahl von Wiederholungen (ab 40) stabil sei (vgl. ebd.: 22). Die Autoren schlussfolgern, dass LLMs noch nicht den Ansprüchen genügen, um bei einer deduktiven Kodierung autonom arbeiten zu können (vgl. ebd.: 25).

Chew et al. (2023) führen zur Evaluierung der Leistung von dem ChatGPT zugrunde liegenden Modell GPT-3.5 Benchmarktests für verschiedene Kodierungsaufgaben durch, wie sie in der qualitativen Forschung üblich sind, in denen die LLM-Performance mit der von menschlichen Codern verglichen wird. Dafür wurden vier verschiedene Datensätze ausgesucht: ein Datensatz mit 2082 Tweets, einer mit 2904 Blogposts, einer mit 2225 Nachrichtenartikeln und einer mit 100 behördlichen Berichten über regionale Wasserqualitäten. Für die einzelnen Datensätze waren Codebücher vorhanden, die sich in ihrem Detailgrad voneinander unterscheiden. Als Indikator für die Performance berechnen die Autoren die sogenannte Interrater Reliability und führen Tests of Randomness durch. Die Ergebnisse der Studie legen nahe, dass GPT-3.5 auf einem

vergleichbaren Level wie menschliche Coder arbeitet, was auch im Zusammenhang mit der einhergehenden Zeitersparnis Implikationen für die Zukunft der qualitativen Forschung haben könne (vgl.: 14). Darüber hinaus bieten die Autoren anhand ihrer eigenen Forschungserfahrung einen Entwurf an, wie eine qualitative Inhaltsanalyse mit einem LLM durchgeführt werden kann (vgl.: 2f.). Dieser sieht vor, zusammen mit dem LLM ein Codebuch zu entwickeln, dieses sowohl von dem LLM als auch von menschlichen Codern auf ein zufällig gezogenes Sample anzuwenden, die Interrater Reliability zu berechnen und bei einem akzeptablen Ergebnis das Codebuch auf ein größeres Sample anzuwenden (vgl. ebd.: 3).

Wang et al. (2023) vergleichen anhand der Durchführung einer Sentiment-Analyse die *zero-shot* Performance, also die Fähigkeit, eine Aufgabe ohne zusätzliche Beispiele zu bearbeiten, von GPT-3.5 Turbo (*Temperature* = 0) mit der Leistung von anderen, auf eine solche Analyse trainierten Sprachmodellen. Dafür nutzen die Autoren 18 verschiedene Datensätze, anhand derer fünf verschiedene Textanalyseaufgaben bearbeitet werden. Nach Berechnung des F1-Maßes und einer händisch durchgeführten Evaluation der Genauigkeit der Ergebnisse, bescheinigen Wang et al. (vgl. 2023: 4f.) GPT-3.5 Turbo eine beeindruckende *zero-shot* Performance, die die spezialisierten Modelle teilweise sogar überschreitet, was sich durch den Wechsel auf *few-shot* Prompts, also Prompts mit mehreren Beispielen zur Lösung einer Aufgabe, noch verstärkt. Ein Vorteil von GPT-3.5 Turbo gegenüber spezialisierten Modellen liegt außerdem in der besseren Fähigkeit, Material über verschiedene Domänen hinweg zu analysieren, gleichwohl dies je nach Domäne zu qualitativ unterschiedlichen Ergebnissen führt (vgl. ebd.: 7), während spezialisierte Modelle in der Regel auf bestimmte Themen trainiert werden.

Eine zurückhaltende Haltung zur Verwendung von ChatGPT in der qualitativen Sozialforschung nehmen Ziems et al. (2023) ein. Die Autoren untersuchen anhand von mehreren Forschungsfragen das Potential von LLMs, die Computational Social Sciences (CSS) zu transformieren. Für jedes mit den CSS in Verbindung stehende Forschungsfeld, wie beispielsweise die Soziologie oder die Politikwissenschaften, wurden typische Aufgaben des qualitativen Forschungsprozesses mit jeweils passenden, dem Komplexitätslevel entsprechenden kategorisierten Daten erstellt. Anhand dieser Aufgaben wurde die Performance verschiedener Modelle getestet. In Bezug auf die hier durchgeführte Arbeit ist vor allem relevant, dass den Ergebnissen folgend, ChatGPT auf dem *Utterance*-Level, also bei der Kodierung von einzelnen Äußerungen, vor

allem bei der Erkennung von Falschinformationen und Haltungen stark performt (ebd.: 6f). Insgesamt kommen die Autoren zu dem Schluss, dass LLMs als zusätzlicher Coder neben den menschlichen Codern einbezogen werden könnten, die Aufgabe allerdings nicht komplett abgegeben werden sollte. Ihr Output müsse außerdem immer von den Forschenden validiert werden (ebd.: 17).

Xiao et al. (2023) fragen ebenfalls inwiefern die Ergebnisse von LLM (GPT-3) und Experten beim deduktiven Kodieren im Zuge einer qualitativen Inhaltsanalyse vergleichbar sind und untersuchen darüberhinausgehend, wie sich die Ergebnisse des Sprachmodells unterscheiden, wenn unterschiedliche Prompts verwendet werden. Als Material verwenden die Autoren 668 „curiosity-driven childrens questions“ (vgl.: 76). Für den Kodierungsprozess werden verschiedene Ansätze für das Prompt-Design ausprobiert: erstens wird zwischen *codebook-centered* und *example-centered* unterschieden. Ersterer spiegelt das Format eines klassischen Codebuchs wider, das in das Modell eingelesen wird und in dem ein Code, eine Beschreibung und ein Beispiel dafür angegeben werden. Letzterer gibt wiederum als Fließtext ein Beispiel an und begründet die dazugehörige Codeauswahl. Zweitens untersuchen die Autoren Unterschiede zwischen *zero-shot*, *one-shot* und *few-shot learning*, die die Anzahl der Beispiele im Prompt beschreiben: Keines, ein einzelnes Beispiel oder mehrere (vgl. ebd.). Die Ergebnisse durch die Berechnung der Interrater Reliability (IRR) mit Cohen’s Kappa legen den Schluss nahe, dass GPT-3 zwar angemessene bis substantielle Übereinstimmungen mit den Experten erreicht, diese jedoch weit hinter der IRR der Experten untereinander zurückliegen. Die besten Leistungen können demnach erreicht werden, wenn der Codebuch-Ansatz mit einem einzelnen Beispiel verwendet wird.

Die Reliabilität von ChatGPT bei der Kodierung mit *zero-shot* Prompts untersucht auch Reiss (2023) anhand 234 zufällig ausgewählter Websites, die ChatGPT thematisch in *Nachrichten* und *Nicht-Nachrichten* klassifizieren soll. Die Arbeit folgt der Prämisse, dass Outputs von ChatGPT aufgrund seiner nicht-deterministischen Funktionsweise generell variieren und dass Pooling, also die Zusammenführung der Ergebnisse verschiedener Coder, eine Möglichkeit darstellt, die Reliabilität von Kodierungen zu verbessern. Vor diesem Hintergrund werden verschiedene Parameter wie die Formulierung der Prompts, die Temperatur und die Wiederholungsanzahl variiert, während die Reliabilität mittels Krippendorfs Alpha errechnet wird. Die besten Ergebnisse lassen sich demnach mit einer niedrigen Temperatureinstellung, einer

ausführlichen Aufgabenbeschreibung und Pooling von drei oder mehr Wiederholungen der Kodierungen erzielen; von einer nicht überwachten Verwendung wird jedoch abgeraten.

3.2 ChatGPT für die Generierung von (Programmier-)Code

Da die qualitative Inhaltsanalyse großer Textmengen mit einem der GPT-Modelle auf die Programmierung derselben angewiesen ist und sie daher Anwendern bei dieser Aufgabe ebenfalls von Nutzen sein können, sei hier ein kurzer Einblick in die Forschung zu ChatGPT als *Coding Assistent* gegeben. LLMs zeigen bei Programmieraufgaben meist sehr gute Leistungen, oft besser als bei der Generierung von Text (vgl. Borji 2023: 16). Obwohl die Performance beim Programmieren auf teilweise menschlichem Niveau liegt, ist dennoch immer die Validierung von menschlichen Programmierern nötig (vgl. Poldrack et al. 2023). Nichtsdestotrotz eignet sich ChatGPT sowohl zur Verwendung beim Lernen von Programmiersprachen oder -konzepten als auch als Hilfe beim Debugging von selbst geschriebenem Code (vgl. Borji 2023: 18)

Für die Durchführung einer Textanalyse mit LLMs sind bereits einige Tools und Anwendungsbeschreibungen verfügbar. Törnberg (2023b) gibt Forschenden und Studenten eine Komplettanleitung zur Verwendung der GPT-Modelle von OpenAI zur Hand, die sich unter anderem auch der Programmierung der Modelle in Python widmet. Mit Werkzeugen wie *Cody*, die KI und Machine Learning nutzen, um beim Kodieren von Textdaten im qualitativen Forschungsprozess zu unterstützen, oder *QualiGPT* auf Basis der GPT-Modelle, fällt das Programmieren hingegen bereits weg (vgl. Rietz & Maedche 2023; Zhang et al. 2023). Darin zeigt sich auch, dass die Nutzung von LLMs in der Wissenschaft noch in der Phase der *Early Adopters* ist und sich mittlerweile der frühen Mehrheitsnutzung annähert (vgl. Rogers 2003: 281f.).

3.3 Limitationen und Risiken von LLMs

Wie alle Methoden bringt auch der Einsatz von Sprachmodellen in der qualitativen Sozialforschung und in der wissenschaftlichen Arbeit allgemein gewisse Risiken und Limitation mit sich. Während es wahrscheinlich ist, dass einige davon mit einer zunehmenden Einbettung der Modelle in den Forschungsprozess ausgeräumt werden, sind sie für den Moment dennoch ernst zu nehmen und müssen adressiert werden. Im Folgenden wird ein kurzer Überblick über die bisherigen Standpunkte in der Forschung zu diesen Limitationen und Risiken gegeben.

Eines der großen Risiken, die mit einer vermehrten Nutzung von LLMs in der Forschung einhergehen, ist der Mangel an Transparenz bezüglich der Trainingsdaten. Aktuelle KI-Technologien sind fast alle Produkte und Eigentum großer Technologiekonzerne oder werden von diesen in großem Stil finanziell gefördert (vgl. van Dis et al. 2023: 225). Informationen über die Trainingsdaten, mit denen die Modelle trainiert werden, sind dementsprechend in der Regel nicht öffentlich zugänglich, um im Sinne des wirtschaftlichen Wettbewerbs die Kapitalinteressen jener Konzerne gegenüber der Konkurrenz zu schützen, was die Modelle zu komplexen Black-Boxes macht (vgl. Salah et al. 2023: 4). Die Lösung zu diesem Problem liegt in der Entwicklung und wissenschaftlichen Nutzung von Open-Source LLMs (ebd.). Eine solche Open-Source Plattform würde verschiedene Probleme lösen, die sich aus der Intransparenz dieser Konzerne ergeben, zum Beispiel die potenziell bedrohte Replizierbarkeit von Artikeln, bei denen kommerzielle LLMs genutzt wurden, denn ohne das Wissen, wie ein Ergebnis zustande kommt, ist eine Replikation nicht möglich. Abgesehen von der probabilistischen Funktionsweise und der daraus folgenden, sich fortsetzenden Unterschiedlichkeit des Outputs von beispielsweise ChatGPT, besteht immer auch die Möglichkeit, dass Modelle von ihren Entwicklern von heute auf morgen verändert werden, sodass sich der Output vollkommen verändern könnte; genauso besteht die Möglichkeit, dass Modelle gänzlich vom Markt genommen werden (vgl. Spirling 2023: 413).

Die Undurchsichtigkeit dieser Black-Box verhindert oder erschwert zumindest die Bewertungen von Genauigkeit, Reliabilität und Bias generierten Texts (Salah et al. 2023: 4). So hat zum Beispiel Salleh (2023) untersucht, wie fehleranfällig ChatGPT beim Zusammenfassen von wissenschaftlichen Texten ist. ChatGPT werden dafür Texte zur Zusammenfassung zur Verfügung gestellt, die eigenen Zusammenfassungen sollen anschließend von ChatGPT den entsprechenden Artikeln wieder zugeordnet werden und außerdem mit den Abstracts der Autoren verglichen werden. Während die Zusammenfassungen von ChatGPT eine auf einer 10-Punkte Skala mittlere Nähe (5-7) zu den tatsächlichen Abstracts aufzeigen, wurden dennoch oft relevante theoretische Informationen weggelassen. Weiterhin ist das Modell weder in der Lage, seine eigenen Zusammenfassungen noch die Abstracts der Autoren den richtigen Artikeln zuzuordnen und zeigt außerdem ein deutliches Bias für Autoren und Zeitschriften mit höherem Ranking (vgl. Salleh 2023: 11). Diesen Problemen kann ohne Transparenz bezüglich der Trainingsdaten und der Programmierung nicht adäquat begegnet werden, weshalb nicht nur qualitativ minderwertige Ergebnisse, sondern auch unfaire

Schlussfolgerungen und falsche Interpretationen die Folge sein können (vgl. Salah 2023: 3). Bias ist jedoch auch in einem soziokulturellen Sinne ein bekanntes Problem bei LLMs: „Bias in a language model refers to the systematic inaccuracies or stereotypes in the generated language output, which are influenced by the training data and reflect the societal and cultural prejudices that exist in that data" (Borji 2023: 11). Obwohl Unternehmen wie OpenAI Maßnahmen umsetzen, die diese Form des Bias verhindern sollen (vgl. ebd.), bedarf es dennoch der genauen Aufmerksamkeit der Forschenden bei der Arbeit mit solchen Modellen. Santukar et al. (2023: 10f.) zeigen zum Beispiel, dass dieser Problematik zumindest teilweise durch entsprechendes Prompt Engineering begegnet werden kann.

Obwohl die oft genannten Biases von LLMs und KI im Allgemeinen ein ernstzunehmendes Risiko für die wissenschaftliche Arbeit darstellen, argumentieren Argyle et al. (2023), dass sich dieser Bias gerade in den Sozialwissenschaften zu Nutze gemacht werden kann. Die Autoren zeigen, dass ein solches Modell nicht nur den Bias ihres Nutzers wiedergeben, sondern viele verschiedene Biases unterschiedlicher Standpunkte, die sie sich über die Trainingsdaten angeeignet haben. Mittels einer Fine-Tuning Technik, die die Autoren *Silicon Sampling* nennen und bei der tausende Biografien menschlicher Studienteilnehmer eingelesen werden, werden künstliche Samples erstellt, die verschiedenen menschlichen Samples sehr ähnlich sind. So könnten sich, insbesondere mit der weiteren Verbesserung von LLMs, neue Türen für die Sozialforschung eröffnen, vor allem als eine kostengünstige Möglichkeit, Forschungsvorhaben mit menschlichen Samples im Voraus genauer zu planen. Beispielsweise könnten solche *Silicon Samples* menschliche Samples beim Pretesting ersetzen.

Andere ethische Risiken neben den bereits genannten Biases sehen Khlaif et al. (2023:29f.) bei Fragen der Urheberschaft, wie beispielsweise bezüglich der Klärung der Ko-Autorschaft bei der Verwendung von ChatGPT zur Generierung von Text, oder bezüglich der Eigentümerschaft des mit ChatGPT generierten Outputs. Auch die Integrität und Qualität der Forschung könne durch die unachtsame Verwendung von ChatGPT leiden. Bei der Generierung von wissenschaftlichen Texten muss beachtet werden, dass das Modell dazu neigt, wissenschaftliche Referenzen zu erfinden, und dass ChatGPT aufgrund seiner Eigenschaften als *Foundation Model* nicht in der Lage ist, neue Erkenntnisse zu produzieren, sondern sich immer auf seine Trainingsdaten bezieht, was außerdem Bedenken in Bezug auf mögliche Plagiate nährt (vgl. ebd.: 30f.).

4. Methode und Daten

4.1 Daten

Für die qualitative Inhaltsanalyse, anhand derer die Eignung von GPT-3.5 Turbo für die Nutzung in der qualitativen Sozialforschung festgestellt werden soll, wird eine Studie von Forchtner und Lubarda (2022) als Orientierung ausgewählt. Die Studie eignet sich insofern, als dass sie klare Anweisungen hinsichtlich der Datenakquise enthält und dadurch, dass die Autoren ein Codebuch nutzen, was für einen Vergleich von deduktiver und induktiver Kodierung genutzt werden kann. Die Autoren nutzen für ihre Studie ein Sample von 792 Beiträgen von Abgeordneten rechtsradikaler- und extremer Parteien aus dem Europaparlament (ebd.: 53). Da auch auf Nachfrage bei den Autoren des Originalartikels aufgrund der britischen Gesetzgebung kein Zugang zum Material ermöglicht werden konnte, wird das Material mit Orientierung an den Beschreibungen der Datenakquise im Artikel zusammengestellt. Dafür wird das Statistikprogramm R genutzt, insbesondere die beiden Pakete „RSelenium“ (Harrison 2022) und „rvest“ (Wickham 2022). Die Nutzung von R in diesem Kontext bietet sich aus zweierlei Hinsicht an. Erstens beinhaltet R im Gegensatz zu anderer Software sowohl Tools wie das Webscraping als auch Statistikanwendungen. Zweitens ist R in den Sozialwissenschaften weit verbreitet und zur kostenlosen Nutzung verfügbar, womit ein niedrigschwelliger Einsatz möglich ist, um sich am hier verwendeten Arbeitsprozess, von der Akquise der Daten bis zu ihrer Analyse, orientieren zu können.

Entsprechend des Artikels von Forchtner und Lubarda (2022: 53) wurden zunächst Listen der Abgeordneten anhand der dort vorgenommenen Parteienauswahl für die sechste, siebte und achte Legislaturperiode erstellt (2004-2019). Auf den Websites der einzelnen Abgeordneten, die das Europaparlament (vgl. European Parliament o. D.) anbietet, wurden alle Beiträge berücksichtigt, die sich unter den Gliederungspunkten „Contributions to plenary debates“ und „Written explanations of vote“ fanden. Die Beiträge wurden von dort mittels der Tools zum Webscraping, die die oben erwähnten R-Pakete *RSelenium* und *rvest* bereitstellen, in einen Datensatz überführt. Webscraping kann nach Zhao (2022: 951) definiert werden als eine besonders leistungsstarke Technik der automatischen Extraktion großer Mengen an Daten über das Hypertext Transfer Protocol (HTTP) oder einen Webbrowser. Dabei wird eine Automation programmiert, die auf Basis von vorher festgelegten Parametern Webseiten nach Texten durchsucht und diese herunterlädt.

Die so heruntergeladenen Beiträge der Abgeordneten wurden anschließend basierend auf den Titeln der Debatten, in deren Kontext sie vorgetragen wurden, gefiltert, wobei nur Beiträge belassen wurden, deren Debattentitel mindestens einen der folgenden Begriffe beinhaltet: „*climate, CO_2, carbon dioxide, greenhouse* or *global warming*“ (Forchtner & Lubarda, 2022: 53). Die Wörter zur Filterung der Texte wurden mit ChatGPT in alle Amtssprachen der EU-Länder übersetzt, um auch Beiträge, die nicht auf Englisch vorliegen, zu berücksichtigen. Während die Autoren händisch 792 Beiträge fanden (vgl. ebd.), lassen sich mit dieser hier beschriebenen Methode 947 Beiträge herunterladen. Ein Grund hierfür könnte in einer gründlicheren Übersetzung der Filterbegriffe zu finden sein oder in einer fehlenden Präzision der manuellen Datensammlung der Autoren.

4.2 Methodik

Um der Frage nach der Eignung von GPT-3.5 Turbo für die qualitative Inhaltsanalyse nachzugehen, wird in dieser Arbeit die Performance des Modells mit der von Experten bei der deduktiven Inhaltsanalyse verglichen und anschließend einer induktiven Inhaltsanalyse des Modells gegenübergestellt. Die Merkmale dieser beiden Analyseansätze wurden bereits in Kapitel 2.3 erläutert. Auf Grundlage des Artikels Forchtner und Lubarda (2022), aufbauend auf Arbeiten von van Rensburg (2015) und Rahmstorf (2004), wird dafür zunächst ein Codebuch erstellt[1]. Das Codebuch wird sowohl dem GPT-Modell als auch zwei menschlichen Experten zusammen mit der Aufgabe, eine deduktive Kodierung vorzunehmen, vorgelegt sowie mit einer Auswahl von zufällig aus dem Materialkorpus ausgewählten 20 Beiträgen, die als Analysegegenstand dienen. Die Analyse durch das Modell wird, in Anlehnung an die in Kapitel 3.1 vorgestellten Forschungsdesigns (vgl. Gilardi et al. 2023; Tai et al. 2023; Reiss 2023), 5-Mal durchgeführt; dies geschieht jeweils bei Temperatureinstellungen von 0.0, 0.5 und 1.0. Je höher die Temperatur, desto zufälliger und kreativer wird der Output des Modells, weshalb eine Erfassung verschiedener Temperaturen für die Evaluation sinnvoll ist; generell kann dieser Parameter Werte von 0 bis 2 annehmen. Anschließend wird pro Temperatureinstellung die Intercoder-Reliabilität (ICR) der GPT-Analyseergebnisse untereinander und dann in Verbindung mit denen der Experten errechnet. Ersteres dient der Feststellung der Konsistenz der KI-generierten Ergebnisse und zweiteres dem Vergleich der Ergebnisse mit denen der Expertenanalysen. Anschließend werden die Kodierungen im Detail mit der im Codebuch vorgesehenen Anwendung der Codes

[1] Datei: *Codebuch.pdf*

verglichen. Zuletzt werden mit dem Sprachmodell GPT-3.5 Turbo induktive Kodierung vorgenommen, bei der das Modell eigene Kategorien entwickeln soll. Diese Kodierungen erfolgen bei Temperatureinstellungen von 0.5, 1.0 und 1.5. Die Leistung des Modells bei der Kategorienbildung wird zunächst offen bewertet und die Kategorien anschließend, soweit es möglich ist, dem für die deduktive Inhaltsanalyse verwendetem Codebuch gegenübergestellt, um beurteilen zu können, ob sich ChatGPT für eine solche Analyse eignet.

4.3 Programmierung von GPT-3.5 Turbo und Prompt für die deduktive Kodierung

Das Ziel dieser Arbeit ist die Untersuchung der Frage, ob sich das LLM GPT-3.5 Turbo, welches auch ChatGPT zugrunde liegt, dafür eignet, Sozialwissenschaftler bei der Kodierung von Text im Rahmen der Durchführung einer qualitativen Inhaltsanalyse zu unterstützen. Für das Tool ChatGPT ist auf den ersten Blick absehbar, dass es sich kaum für eine solche Aufgabe eignet, da die Zahl der verwendbaren Tokens pro Anfrage zu klein ist, als dass eine sich lohnende Textmenge kodiert werden könnte. Pro Anfrage stehen lediglich für Eingabe und Ausgabe insgesamt 4096 Tokens zur Verfügung, während OpenAI angibt, dass ein Token ungefähr vier Buchstaben und damit durchschnittlich 0,75 Wörter in der englischen Sprache darstellt (vgl. OpenAI Platform o.D. a).

Stattdessen bietet sich die Nutzung von OpenAIs API an, die einen direkten Zugriff auf die Sprachmodelle des Unternehmens ermöglicht. Die API kann beispielsweise mittels des Python Pakets *openai* genutzt werden, welches von OpenAI direkt zur Verfügung gestellt wird (OpenAI Platform o.D. b). Andere Zugriffmöglichkeiten existieren ebenfalls, wie unter anderem Pakete für R, die jedoch nicht von OpenAI entwickelt wurden, weshalb sich die Nutzung von Python empfiehlt. Bei der Programmierung der API-Anfrage bietet es sich außerdem an, Hilfestellung von ChatGPT zu beziehen, um das Modell schnellstmöglich nutzen zu können. Wie in Kapitel 3.2 beschrieben, eignet sich ChatGPT als Programmierassistent und ermöglicht in diesem Fall einen effizienteren Workflow (Borji 2023; Poldrack 2023). Die Ansteuerung der API über Python ermöglicht es nun, mittels einer Schleife einen Prompt beliebig oft in das Modell einzulesen. Dieses Verfahren wird auch „training sample concatenation“ (Lu et al. 2023: 8086) genannt. Der Prompt besteht dabei immer aus der Aufgabenstellung, dem Codebuch sowie jeweils eines Teils des zu analysierenden Textes, bis dieser vollständig eingelesen ist. Da die Outputs des Modells bei Verwendung einer solchen Schleife

ebenfalls in kleineren Abschnitten ausgegeben werden, müssen sie im Anschluss wieder aneinandergefügt werden, was eine einzelne Liste kodierter Textstellen in dem Format ergibt, das vorher im Prompt festgelegt wurde.

Die Prompts bestehen gemäß der in Kapitel 2.2 erläuterten, typischen Struktur aus den Teilen *Instruction*, *Context*, *Input Data* und *Output Indicator*. Der Prompt für die deduktive Kodierungsaufgabe ist unten dargestellt. Der hier gezeigte Teil des Prompts spiegelt lediglich die Teile *Instruction* und *Ouput Indicator* wider; der *Context* wird über das Codebuch eingelesen und die *Input Daten* sind die zu analysierenden Beiträge aus dem Europaparlament. Darüber hinaus nutzt der Prompt die sogenannte *In-Context Impersonation*-Technik, bei welcher das Sprachmodell im Prompt dazu auffordert, sich wie ein Experte auf dem Feld zu verhalten, dem das zu bearbeitende Thema zuzuordnen ist (vgl. Salewski et al. 2023). Der Aufgabenprompt für die deduktive Kodierung sieht schließlich folgendermaßen aus:

> *Ich werde dir nun Redebeiträge zum Klimawandel vorlegen, die du auf diese Art analysieren sollst. Du sollst darin nach Textpassagen suchen, die auf Formen von Skepsis gegenüber dem Klimawandel schließen lassen. Benutze dafür das bereits eingelesene Codebuch und begründe deine Codeauswahl. Bitte stelle sicher, dass die Ausgabe für jede vorgenommene Kodierung das folgende Format hat:*
>
> > *Code: "Code X"*
> > *Textstelle: "kodierte Textstelle [Textnummer]"*
> > *Begründung: "Kodierungsbegründung"*
>
> *Bitte halte dich an dieses Format, um die Konsistenz der Ausgabe sicherzustellen. Du sollst mir also den Code geben, den Satz, den du kodiert hast, sowie die Nummer des Textes, aus dem er stammt, und deine Kodierung dieser Textstelle anschließend begründen. Die Beiträge sind alle nummeriert und es können mehrere Codes pro Text vorkommen. Verhalte dich wie ein Sozialwissenschaftler, der einen Text im Zuge einer qualitativen Inhaltsanalyse deduktiv kodiert.*

4.4 Erfassung der Leistung von GPT-3.5 Turbo

Als eine der Kennzahlen zur Ermittlung der Leistung des Sprachmodells bei der deduktiven Kodierung wird die ICR errechnet. Die Idee der ICR ist gemeinhin, die Konsistenz und Transparenz des Kodierungsprozesses zu erhöhen, um das Vertrauen in die Forschungsergebnisse zu verbessern (O'Connor & Joffe 2020). Es gilt dabei, dass je höher der Wert der ICR, desto höher ist die Reliabilität der Kodierung. Ein Maß für die ICR, das mittlerweile zum Standard in der qualitativen Inhaltsanalyse geworden ist, ist Krippendorffs Alpha (vgl. Kozina et al. 2019: 2). Methodisch bietet sich Krippendorffs Alpha zur Berechnung der ICR an, da es die Möglichkeit bietet, die ICR für mehr als zwei Coder zu berechnen. Daraus ergibt sich die Gelegenheit, die Konsistenz

von GPT-3.5 Turbo bei der Kodierung zu testen, indem diese mehrmals durchgeführt wird und die ICR dieser Durchführungen je Temperatureinstellung errechnet wird. Dies ist notwendig, da sich die probabilistisch erstellten Outputs je Durchführung unterscheiden können (vgl. Paaß & Giesselbach 2023: 37). Dieses Vorgehen orientiert sich unter anderem an dem von Gilardi et al., die die ICR allerdings nicht mit Krippendorffs Alpha berechnen, sondern als „percentage of tweets that were assigned the same label by two different annotators“ (2023: 3). Tai et al. (2023) und Reiss (2023) verfolgen diesen Ansatz ebenso. Krippendorffs Alpha errechnet sich mit folgender Formel, bei der D_o für die beobachtete Abweichung der den Analyseeinheiten zugewiesenen Werten steht und D_e die Abweichung, die bei einer zufälligen Kodierung erwartet werden würde (vgl. Krippendorf 2004: 788):

$$\alpha = 1 - \frac{D_o}{D_e}$$

In einem weiteren Schritt wird zwei Experten das gleiche Sample vorgelegt wie ChatGPT. Diese Experten sind als studentische Hilfskräfte am Institut für Sozialwissenschaften der Universität Oldenburg angestellt. Die Aufgabenstellung ist im Kern dieselbe wie für ChatGPT, unterscheidet sich jedoch in ihrer Formulierung leicht vom Prompt. Für die Experten untereinander wird ebenfalls die ICR berechnet, sowie für die Experten und das Modell je nach Temperatureinstellung. So soll ein Vergleich zwischen Experten- und Modellkodierung ermöglicht werden. Im Folgenden ist die Aufgabenstellung für die Experten dargestellt:

Aufgabe:

> *Vielen Dank, dass du dich bereiterklärt hast, diese Aufgabe zu bearbeiten! Anbei findest du ein Codebuch, anhand dessen du eine Auswahl an kurzen Texten kodieren sollst. Die Texte sind allesamt Redebeiträge von Abgeordneten des EU-Parlament aus den Jahren 2004-2019 zum Thema Klimawandel. Die Codes beschreiben, wie sich verschiedene skeptische Haltungen zum Klimawandel äußern können. Dabei wird zwischen drei verschiedenen Formen unterschieden. Erstens die Skepsis gegenüber der Existenz des Klimawandels, seiner Ursachen und seiner Folgen, zweitens gegenüber den wissenschaftlichen und politischen Prozessen, die klimapolitischen Entscheidungen zugrunde liegen und drittens, gegenüber diesen Entscheidungen selbst.*
>
> *Das Format deiner Antworten soll folgendermaßen aussehen:*
>
> *Code: "Code X"*
> *Textstelle: "kodierte Textstelle [Textnummer]"*
> *Begründung: "Kodierungsbegründung"*

> ***Beispiel***:
> ***Code***: *IAHR*
> ***Textstelle***: *"I feel as if I am at the inaugural conference of a newly-founded religion, a false religion, teeming with false prophets and ideas" [43]*
> ***Begründung***: *Der Redner bezeichnet die laufende Debatte als pseudo-religiöses Ritual und spricht ihr damit ihre Bedeutung ab.*

Abschließend werden die Kodierungen im Detail auf die korrekte Anwendung der Codes untersucht. Anhand der kodierten Textstellen und Begründungen derselben durch das Modell wird ein Vergleich mit der im Codebuch festgehaltenen Bedeutung der einzelnen Codes angestellt. So können mögliche systematische Fehler und die Adäquanz und Plausibilität der von ChatGPT angefertigten Kodierungen festgestellt werden.

4.5 Programmierung von GPT-3.5 Turbo und Prompt für die induktive Kategorienbildung

Die induktive Kategorienbildung mit ChatGPT verläuft nach einem ähnlichen Muster wie die deduktive Kodierung. Es wird dafür ebenfalls über ein Python Skript auf die API von OpenAI zugegriffen. Zunächst wird dasselbe Sample wie bereits bei der deduktiven Kodierung in kleineren Abschnitten eingelesen, da die verwendbare Anzahl der Tokens begrenzt ist. Zu jedem Abschnitt wird ein Prompt beigefügt, der die Anweisung beinhaltet, Kategorien im Stile einer induktiven Kategorienbildung bei der qualitativen Inhaltsanalyse zu bilden. Ebenso wird hier die sogenannte *In-Context Impersonation*-Technik genutzt (vgl. Salewski et al. 2023) und der Prompt folgt der Struktur *Instruction*, *Context*, *Input Data* und *Output Indicator*:

> *Ich werde dir nun einzelne Textabschnitte vorlegen, die Redebeiträge von Europaparlamentsabgeordneten darstellen. Ich möchte, dass du im Stil einer qualitativen Inhaltsanalyse, wie sie in den Sozialwissenschaften angewandt wird, eine induktive Kategorienbildung vornimmst. Die Texte beziehen sich allesamt auf den Klimawandel und seine Konsequenzen. Ich möchte, dass du Kategorien bildest, die die verschiedenen Haltungen zu diesem Thema widerspiegeln. Geh dabei vor wie ein Sozialwissenschaftler, der eine induktive Inhaltsanalyse vornimmt.*
>
> *Bitte stelle sicher, dass die Ausgabe für jede vorgenommene Kodierung das folgende Format hat:*
>
> > *Kategorie: "Name der Kategorie"*
> > *Textstelle: "betreffende Textstelle [Textnummer]"*
> > *Begründung: "Begründung der Kategorie"*

Da aufgrund der Begrenzung der Tokenanzahl das Sample nur abschnittsweise eingelesen und bearbeitet werden kann, kann die Anzahl der von ChatGPT erstellten Kategorien nicht wirksam eingegrenzt werden. Der Prompt wird deshalb für das Sample

mit 20 Texten fünf Mal in einer Schleife ausgeführt, jeweils mit vier neuen Textabschnitten. Eine Beschränkung der Kategorien im Prompt würde jeweils nur für diese vier Textabschnitte je Ausführung gelten. Für jede Ausführung beginnt der Zähler für die Begrenzung also von neuem; bei einer Begrenzung von Zehn würde ChatGPT also zwar möglicherweise nur 4 Kategorien je Ausführung bilden und sich damit im Rahmen der vorgeschriebenen Begrenzung bewegen, bei fünf Ausführungen wären letztlich dennoch 20 Kategorien gebildet worden. Daher muss im Anschluss an diesen ersten Schritt, wie auch in der traditionellen induktiven Kategorienbildung, ein zweiter Schritt zur Verfeinerung der Kategorien erfolgen. Dafür werden die zuvor erstellten Kategorien erneut eingelesen und inhaltlich zusammengefasst, sodass die Anzahl der Kategorien verringert wird. Je nach Samplegröße kann eine Verfeinerung der Kategorien mehrmals nötig sein, um die Begrenzung der Tokenanzahl zu berücksichtigen. Der hier verwendete Prompt für diesen Schritt lautet:

> *Fasse jeweils ähnliche Kategorien in diesem Dokument in neue Kategorien zusammen. Gehe dabei wie ein Sozialwissenschaftler vor, der eine induktive Kategorienbildung im Sinne der qualitativen Inhaltsanalyse vornimmt und versucht die Anzahl der gefundenen Kategorien zu begrenzen.*

Die so zusammengestellten Kategorien werden anschließend auf ihre Plausibilität und Genauigkeit untersucht. Die bis hierhin dargestellten Schritte erfolgen daraufhin mit einem weiteren, größeren Sample des Materials, das aus 50 zufällig aus dem Korpus ausgewählten Texten besteht, um eine größere thematische Bandbreite des Materials abdecken zu können und so die Anzahl der Kategorien zu erhöhen. Dieser Arbeitsprozess wird insgesamt drei Mal durchgeführt, mit jeweils anderen Temperatureinstellungen (0.5, 1.0 und 1.5). Diese wurden gegenüber der deduktiven Kodierung um 0.5 Punkte höher angesetzt, da davon ausgegangen wird, dass eine solch offen formulierte Aufgabenstellung von einer „kreativeren“ Antwort profitieren kann.

5. Ergebnisse

5.1 Ergebnisse der deduktiven Kodierung

Um die Konsistenz der Textausgabe von ChatGPT zu testen, wurde zunächst die ICR für die mehrfach je Temperatureinstellung durchgeführten Kodierungen in Form von Krippendorffs Alpha errechnet. Die ICR gibt in diesem Fall wieder, inwieweit die Kodierungen der einzelnen Durchführungen je Temperatur miteinander übereinstimmen, womit sich die probabilistische Funktionsweise von LLMs kontrollieren lässt. Abbildung 2 zeigt genau dies, wobei darauf hingewiesen sei, dass 12 der insgesamt 34 Codes in keiner für diese Arbeit durchgeführten Kodierungen verwendet wurden und deshalb

nicht in den Grafiken abgebildet werden. An der Abbildung lässt sich ablesen, dass bei einer Temperatureinstellung von 0.0, also der niedrigmöglichsten Einstellung der Zufälligkeit des Modells, insgesamt hohe Werte für Krippendorffs Alpha erreicht werden. Außer für die Codes WANU (0.797), SGCA (-0.008), GPNE (-0.008) und CPFB (0.661) wird das gemeinhin als erforderlich für eine ausreichende Reliabilität angesehene Niveau von mindestens 0.800 erreicht. Bei einer Temperatur von 0.5 hingegen wird dieser Wert lediglich bei dem Code AHNP (0.868), der verwendet wird, um eine direkte Leugnung des Klimawandels oder seiner Konsequenzen zu beschreiben, und CPFB (0.823), der Kritik an der vermeintlichen Ungerechtigkeit des CO^2-Preises beschreibt, erreicht. Bei einer Temperatur von 1.0 wird für keinen Code ein Wert von mindesten 0.8 erreicht. Die Codes mit den höchsten Werten für Krippendorffs Alpha sind hier CPFB (0.440) und GPNE (0.387), der Textstellen markieren soll, in denen sich für eine Trennung von genderspezifischer Politik und Klimapolitik ausgesprochen wird.

Abb. 2: Krippendorffs Alpha nach Codes, deduktive Inhaltsanalyse mit GPT3.5 Turbo

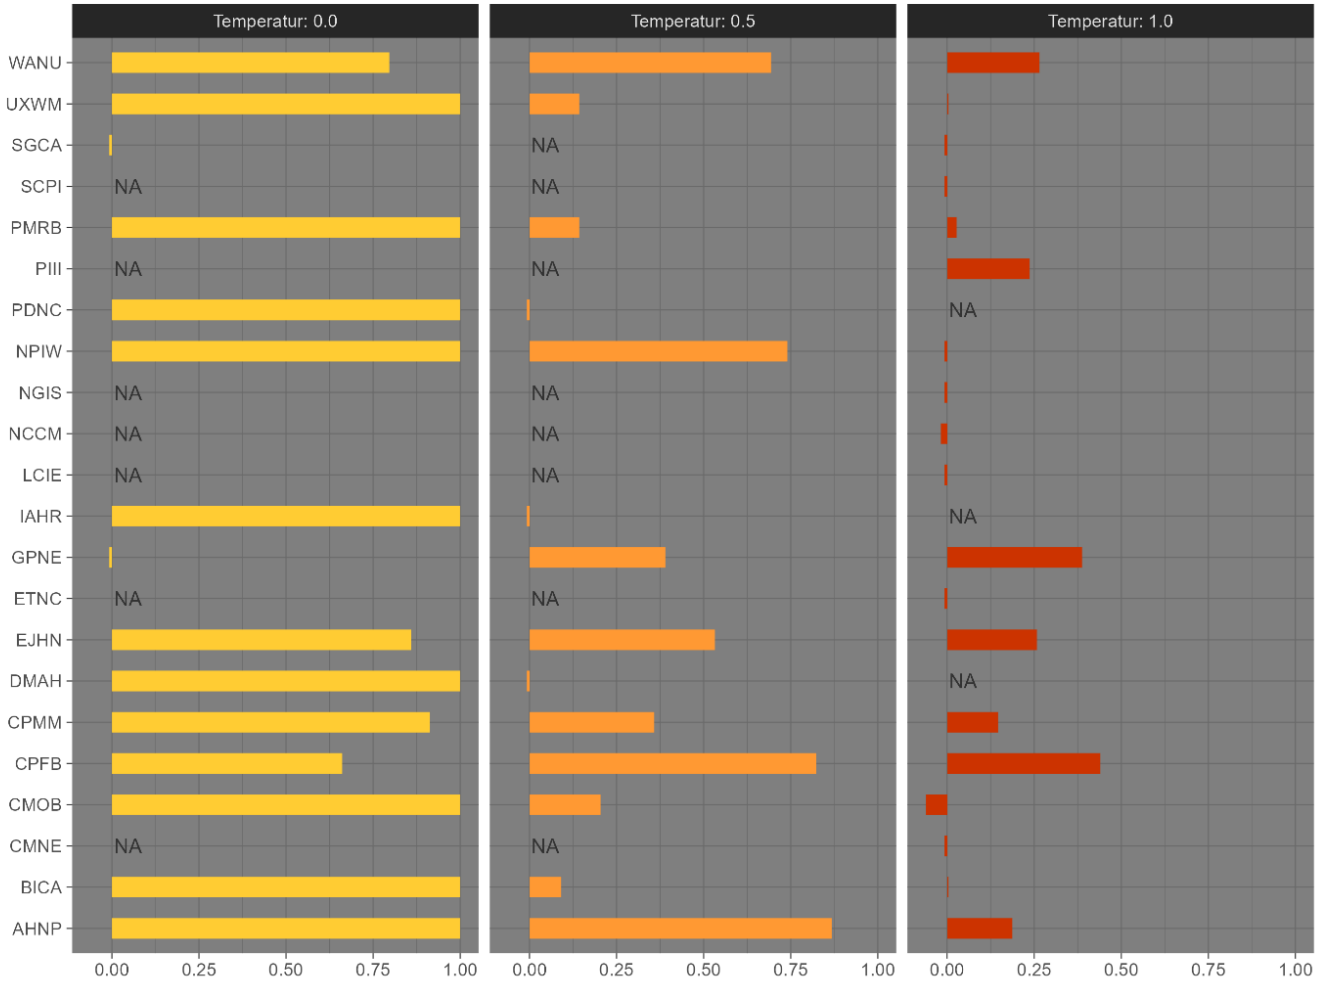

Krippendorffs Alpha nach Codes und Temperatur. NA für Codes, die bei der Kodierung nicht verwendet wurden

Wie sich in Abbildung 2 außerdem auch an der Verteilung der *NA*s, die nicht verwendete Codes markieren, zeigt, unterscheiden sich die Temperatureinstellungen in ihrer Variation beim Kodieren. So werden bei einer Temperatur von 1.0 insgesamt, in allen fünf Kodierungen zusammen, 19 der hier dargestellten 22 Codes genutzt, bei einer Temperatur von 0.5 nur 14 und bei einer Einstellung von 0.0 15 verschiedene Codes. Ein abnehmender Wert von Krippendorffs Alpha mit einer steigenden Zufälligkeit und Kreativität des Outputs erscheint nicht überraschend. Es fällt jedoch auf, dass Codes, die bei der konservativen Einstellung von 0.0 in jeder Kodierung auf die gleichen Textstellen angewandt wurden und dementsprechend einen Wert für Krippendorffs Alpha von 1 erreichen, bei höheren Temperaturen Werte von nahezu 0 ausweisen oder überhaupt nicht mehr verwendet werden. Beispiele hierfür sind die Codes PMRB, der Forderungen nach pragmatischen Ansätzen markiert, und IAHR, der Vorwürfe der Irrationalität beschreibt.

Abb. 3: Durchschnitt von Krippendorffs Alpha je Codergruppe

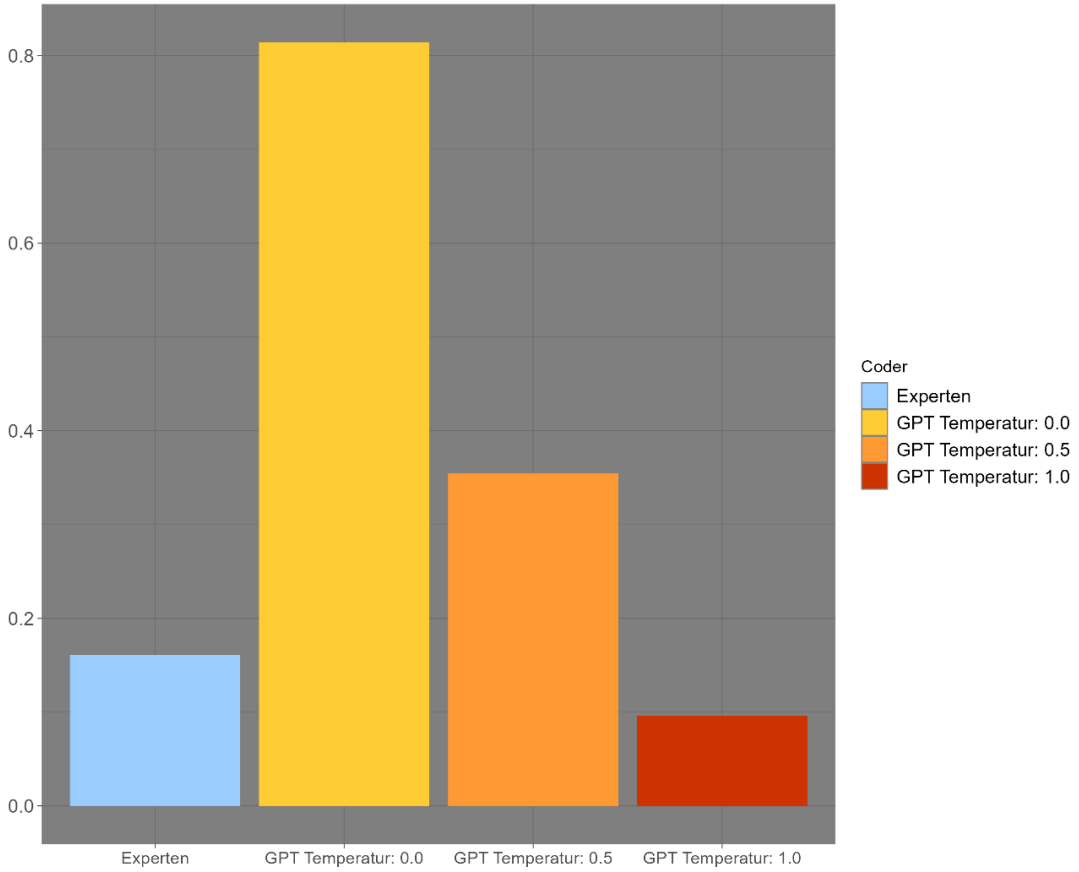

Durchschnitt gebildet aus Krippendorfs Alpha der Codes je Codergruppe.

Anschließend an die Kodierung der Texte durch ChatGPT wurde eine einzelne Kodierung durch zwei Experten durchgeführt. Der durchschnittliche Wert von Krippendorffs Alpha für die Kodierungen der Experten beträgt 0.161 (Abbildung 3), was somit deutlich niedriger als der erforderliche Wert von 0.800 ist. Für ein reales

Forschungsvorhaben würde dies bedeuten, dass vor einer erneuten Kodierung das Codebuch und der diesem zugrundeliegende theoretische Rahmen mit den Codern noch einmal besprochen werden sollte, um im Anschluss eine weitere Kodierung vorzunehmen. Abbildung 3 stellt diesen von den Experten erzielten Wert im Vergleich mit den durchschnittlichen Werten für Krippendorffs Alpha von ChatGPT je Temperatureinstellung grafisch dar. ChatGPT erreicht bei einer Temperatur von 0.0 einen durchschnittlichen Wert von 0.814, was für eine tatsächliche qualitative Inhaltsanalyse ausreichend wäre. Mit den Temperaturen von 0.5 und 1.0 erreicht das Modell lediglich Werte von 0.355 respektive 0.096. Die Expertenkodierung schneidet hinsichtlich der ICR somit lediglich besser ab als ChatGPT bei einer Temperatur von 1.0.

Abb. 4: Krippendorffs Alpha nach Codes, deduktive Inhaltsanalyse mit GPT3.5 Turbo

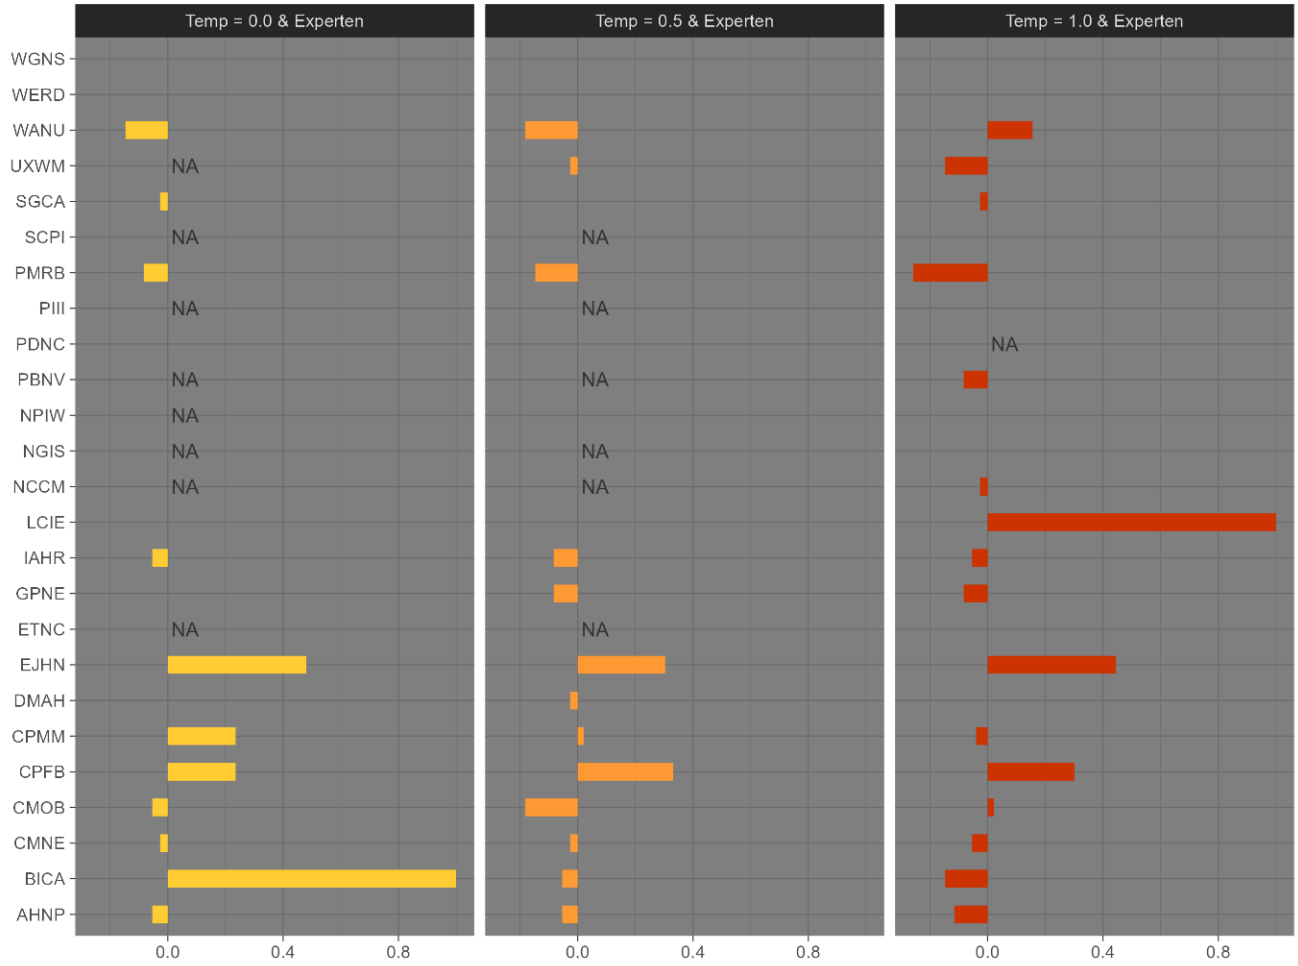

Krippendorffs Alpha von GPT3.5 Turbo und Experten, nach Temperatur und Code. NA für Codes, die bei der Kodierung nicht verwendet wurden

Abbildung 4 zeigt die ICR zwischen Experten und der jeweiligen Kodierungen durch ChatGPT je nach Temperatureinstellung. Die Kodierungen wurden im Vorfeld, gemäß des bei Reiss (2023:8) angewandten Poolings der Ergebnisse, je Gruppe zusammengeführt, sodass für ChatGPT als auch für die Experten eine einzelne Kodierung vorliegt, die alle von der jeweiligen Gruppe verwendeten Codes abbildet. Abgesehen von

den Codes BICA (1.000), der Argumente für Investments in die Anpassung an den Klimawandel markiert, in der ersten Gruppe und LCIE (1.000), der Erwähnungen einer vermeintlichen Klimalobby beschreibt, in der dritten Gruppe, wird für keinen Code ein Wert von über 0.800 erreicht. Wie Abbildung 5 zeigt, sind die durchschnittlichen Werte für Krippendorffs Alpha für Experten und ChatGPT sehr niedrig; die Gruppe mit einer Temperatur von 0.0 erreicht hier den höchsten Wert mit 0.089.

Abb. 5: Durchschnitt von Krippendorffs Alpha - Experten und GPT3.5 Turbo nach Temperatur

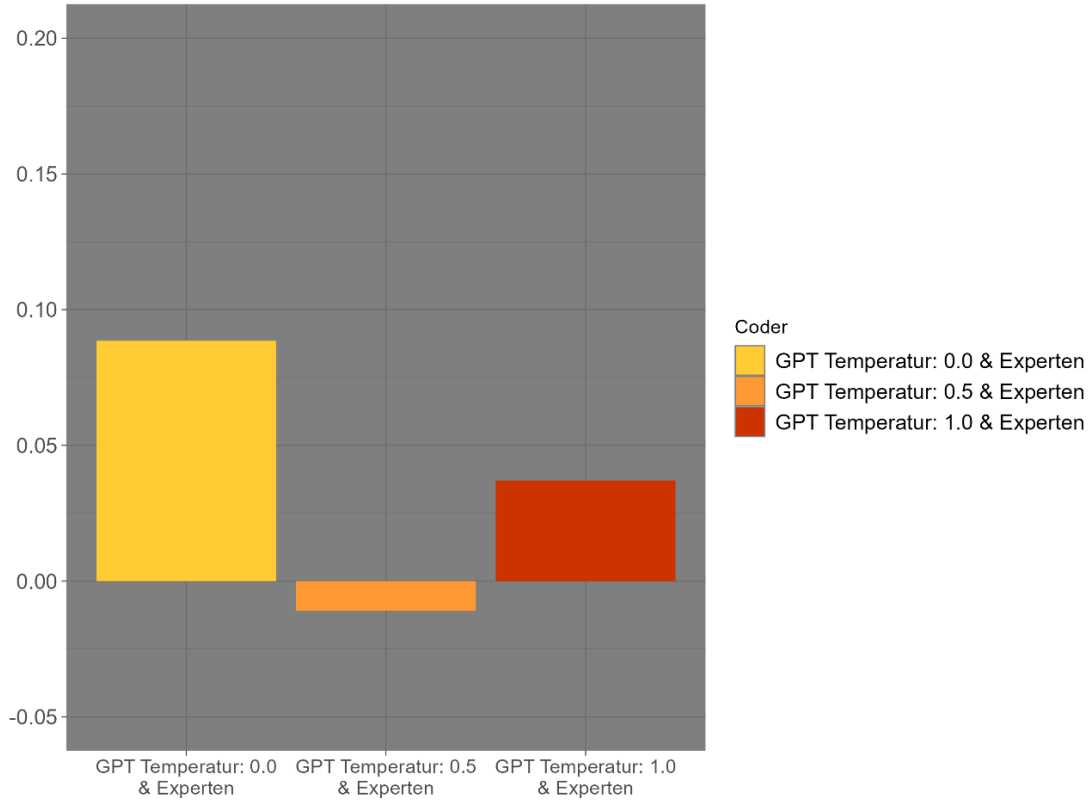

Durchschnitt gebildet aus Krippendorfs Alpha der Codes zwischen Experten und GPT3.5 Turbo

Diese Ergebnisse allein ermöglichen keinen Rückschluss auf die Qualität der Kodierungsergebnisse von ChatGPT. Sie zeigen jedoch inwieweit die Kodierungen konsistent über mehrere Durchführungen hinweg sind und, dass ChatGPT bei Temperaturen von 0.0 und 0.5 konsistenter kodiert als die für diese Arbeit eingesetzten menschlichen Coder in einem ersten Kodierungsverfahren. Weiterhin unterscheiden sich die Ergebnisse von ChatGPT deutlich von denen der menschlichen Coder, wie in den Abbildungen 4 und 5 dargestellt. Um einen tiefergehenden Eindruck auf die Qualität und Angemessenheit der Kodierungen von ChatGPT zu erlangen, ist jedoch eine händische Überprüfung der Ergebnisse nötig. ChatGPT wurde angewiesen zu jedem Code die kodierte Textstelle und eine Begründung der Kodierung widerzugeben, um eine solche Überprüfung zu gewährleisten. Dafür wird jede einzelne kodierte Textstelle mit dem

Codebuch abgeglichen, um festzustellen, ob die von ChatGPT zugewiesenen Codes ihrer im Codebuch verzeichneten Bedeutung entsprechend verwendet worden sind.

Für die Temperatureinstellung von 0.0 kommt ein solcher Vergleich zu dem Resultat, dass durchschnittlich 26,4% der von ChatGPT kodierten Textstellen nicht korrekt sind, die verwendeten Codes also nicht der Textstelle, der sie zugewiesen wurden, entsprechen, was einer durchschnittlichen Fehlerquote von 10,3% bei den Kodierungen der Experten gegenübersteht. Dabei können systematische Fehler festgestellt werden. Zum Beispiel wurde der Text 822[2] in jeder der fünf Durchführungen mit dem Code WANU versehen. WANU steht laut Codebuch für „Wait for global agreement/no unilateral response“, jedoch im Sinne einer skeptischen Haltung, wie das Beispiel im Codebuch deutlich macht: „Why should we fight climate change when China pollutes way more than us and does nothing?“[3] . Während dieser Unterschied durchaus nuanciert ist, wurden außerdem in jeder der fünf Durchführungen Textstellen aus dem Beitrag mit der Nummer 874[4], in dem die Rede von internationaler Zusammenarbeit und Migration ist, mit dem Code EJNH versehen. Dieser steht für das Argument, dass Klimaschutz nicht zu Lasten der Wirtschaft und des Arbeitsmarktes gemacht werden dürfe, was in diesem Text nicht erwähnt wird. Bei Temperaturen von 0.5 und 1.0 waren 46,3% beziehungsweise 61,3% der zugewiesenen Codes nicht korrekt. Entsprechend der bereits vorgestellten Ergebnisse bezüglich der Konsistenz je Temperatur ziehen sich zwar weiterhin, teilweise dieselben, systematischen Fehler durch die Kodierungen, mit steigender Zufälligkeit des Outputs werden sie jedoch auch unvorhersehbarer. So wird der bereits zitierte Text 822[2] bei einer Temperatur von 1.0 einmalig mit dem Code PBNV kodiert, der Vorwürfe gegen das Peer Review Verfahren im Wissenschaftsbetrieb markieren soll. Ein weiterer systematischer Fehler ist außerdem beispielsweise die durchgehend falsche Anwendung des Codes GPNE, mit dem Äußerungen gegen eine Vermischung von Klima- und Genderpolicy kodiert werden sollen. Dieser Code passt zu keinem der Texte im Sample, wird jedoch unter anderem in neun der insgesamt 15 Kodierungen dem Text 313[5] zugeordnet, acht davon bei Temperaturen von 0.5 oder 1.0.

---

[2] "Ich habe dafür gestimmt, da die Zusammenlegung des Emissionshandelssystems der EU und der Schweiz gewährleistet, dass die gleichen Bedingungen für beide Handelspartner beste-hen [sic!]."
[3] Datei: *Codebuch.pdf*
[4] Datei: *txt_sample.txt*
[5] „Dieser Bericht setzt leider den gescheiterten Ansatz fort, neue Finanzierungsinstrumente auf globaler Ebene hervorzuheben, die Anerkennung des Status eines "Klimaflüchtlings" zu betonen und die EU-Klimapolitik im Allgemeinen als kurzsichtig zu bezeichnen“ (Übersetzung, Datei: *txt.sample.txt*)

5.2 Ergebnisse der induktiven Kategorienbildung

Bei der Bearbeitung der Aufgabe zur induktiven Kategorienbildung hat ChatGPT bei einer Temperatureinstellung von 0.5 aus dem kleinen Sample, das auch bei der deduktiven Kodierung verwendet wurde, fünf Kategorien mit 20 Subkategorien gebildet[6]. Die übergeordneten Kategorien bestehen aus:

1. *Zustimmung und Unterstützung,*
2. *Ablehnung und Kritik,*
3. *Internationale Zusammenarbeit,*
4. *Zusammenhang zwischen Wirtschaft und Umweltschutz,* und
5. *Schutz der Umwelt.*

Die Subkategorien sind teilweise jedoch fragwürdig eingeteilt. So wird unter der zweiten Kategorie *Ablehnung und Kritik* beispielsweise zwischen *Kritik an Klimapolitik und Bürokratie, Ablehnung von Klimapolitik und Bürokratie, Kritik an den Klimapolitiken der EU* und *Ablehnung von EU-Klima- und Energiepolitik* unterschieden. Eine Einteilung in Ablehnung und Kritik mit je einer Kategorie für jeweils Klimapolitik, Energiepolitik und Bürokratie, wäre womöglich passender. Weiterhin ist die Subkategorie *Zusammenhang zwischen Wirtschaft und Umweltschutz* zu breit gefächert und die Subkategorie *Ablehnung von Klimawandelalarmismus* unter der Kategorie *Schutz der Umwelt* fehl am Platz.

In einem zweiten Arbeitsschritt wurde der Prompt mit einem anderen, größeren Sample mit 50 Textabschnitten durchgeführt. Dabei wurden acht Kategorien gebildet, hier jedoch mit 44 Subkategorien[7]. Die Kategorien sind:

1. *Zweifel an der Existenz des Klimawandels,*
2. *Kritik an Verwendung des Begriffs „Kohlenstoffemissionen",*
3. *Frage nach den Auswirkungen des Klimawandels,*
4. *Frage nach den Ursachen des Klimawandels,*
5. *Kritik an einseitigen Maßnahmen zur Bekämpfung des Klimawandels,*
6. *Forderung nach Diversifizierung der Energiequellen,*
7. *Ablehnung von Maßnahmen zum Klimaschutz,* und
8. *Klimawandel als Teil einer globalen Agenda.*

Zunächst ist festzuhalten, dass die Subkategorien der Kategorien 2 und 6 thematisch weit über den Titel der Kategorie hinausgehen. Unter Kategorie 2 finden sich nicht nur Subkategorien, die sich auf Kohlenstoffemissionen beziehen, sondern auch auf verschiedene andere Bestandteile von Klimapolitik, die kritisiert werden. Weiterhin bezieht sich eine der Kategorien auf Auswirkungen von Maßnahmen auf Italien, was sehr

[6] Datei: *merged_categories_kleines_sample_05.txt*
[7] Datei: *merged_categories_großes_sample_05.txt*

spezifisch ist und damit demonstriert, dass eine Abstraktionsleistung (vgl. Elo & Kyngäs 2008: 111) im Anschluss nötig bleibt. Es gibt außerdem unter der vierten Kategorie keine Subkategorien; sie hätte stattdessen als Subkategorie unter der ersten Kategorie eingeordnet werden müssen. Alles in allem konnte ChatGPT jedoch zum größten Teil plausible Kategorien bilden, die eine Vielzahl der im Sample angesprochenen Themen abbilden. Da der Prompt im Sinne der induktiven Inhaltsanalyse keine Forderung einer theoretischen Eingrenzung an das Modell stellt und somit nicht nur nach Kategorien zur Klimawandelskepsis nach van Rensburg (2015) gesucht wurde, ist ein Vergleich mit dem oben verwendeten Codebuch nur bedingt möglich. Zwölf der hier induktiv erstellten Subkategorien sind jedoch so oder in ähnlicher Form in diesem Codebuch enthalten, was ein Indikator für ihre Plausibilität sein kann.

Für einen Vergleich verschiedener Temperatureinstellungen werden diese beiden Arbeitsschritte bei einer Temperatur von 1.0 wiederholt. Dabei wurden von ChatGPT aus dem ersten Sample mit 20 Textabschnitten sechs Kategorien mit insgesamt 15 Unterkategorien gebildet[8]. Die übergeordneten Kategorien setzen sich zusammen aus:

1. *Zusammenarbeit und internationale Kooperation,*
2. *Kritik an Klimapolitik und Klimakonferenzen,*
3. *Umweltschutz und Zustimmung,*
4. *Ablehnung von Klimawandelmaßnahmen,*
5. *Betonung der Wirtschaft für Umweltschutz [sic!], und*
6. *Zustimmung des Klimawandelschutzprogramms.*

Die Subkategorien erscheinen diesen in passender Weise zugeordnet zu sein, sind jedoch nicht immer klar umrissen. Eine der Subkategorien von *Ablehnung von Klimawandelmaßnahmen* lautet beispielsweise *Ablehnung aufgrund bestimmter Aspekte*. Hier wird erst mit einem Blick in die Begründung der Kategorienbildung ersichtlich, dass es in dem Text, anhand dessen diese Kategorie gebildet wurde, um die Ablehnung von CO_2 als „wesentliche Säule“[9] eines Abkommens geht. Hier wäre eine manuelle Überprüfung nötig, damit unscharf formulierte Kategorien verfeinert werden können.

Für die Temperatur von 1.0 wird ebenfalls auch das zweite, größere Sample mit 50 Texten zur Kategorienbildung verwendet. Aus diesem Sample konnte ChatGPT 10 übergeordnete Kategorien mit 37 Subkategorien bilden[10]; exemplarisch in Tabelle 1 dargestellt. Wie bereits bei den Kategorien des ersten Samples gibt es auch hier einige unscharfe Subkategorien, wie zum Beispiel zweimal die Kategorie *Ablehnung der*

[8] Datei: *merged_categories_kleines_sample_1.txt*
[9] Datei: *kleinesSample1.txt*
[10] Datei: *merged_categories_großes_sample_1.txt*

Maßnahmen zum Klimawandel, einmal unter Kategorie 2 – *Kritik an den Maßnahmen zur Bekämpfung des Klimawandels* – als auch unter Kategorie 8 – *Ablehnung des Paris-Abkommens*. Ein anderes Beispiel ist die Subkategorie *Kritik an der Abhängigkeit von Batterierohstoffen aus Ländern wie China*, die unter Kategorie 5 – *Kritik an der Nutzung von Atomenergie* – als einzige Subkategorie gezählt wird. Nicht nur ist diese Zuordnung nicht korrekt, es außerdem in der von ChatGPT zitierten Textstelle an keiner Stelle die Rede von einer batteriebezogenen Rohstoffabhängigkeit. 17 der von ChatGPT gebildeten Subkategorien finden sich darüber hinaus in mindestens ähnlicher Formulierung im Codebuch wieder (siehe Tabelle 1), was auch hier ein weiterer Indikator für die Plausibilität sein kann.

Eine händische Überprüfung der Ergebnisse von ChatGPT bleibt dennoch nötig, wie sich unter anderem darin zeigt, dass sich einige der Kategorien speziell auf die Klimapolitik der Europäischen Union beziehen. Dies ist dem Material geschuldet und kann in einer händischen Überarbeitung dem Forschungsvorhaben entsprechend angepasst werden. Da bei der induktiven Inhaltsanalyse die Theoriegenerierung im Vordergrund steht, liegt eine inhaltliche Eingrenzung der Kategorienbildung immer im Ermessen des Forschenden. Außerdem ist eine Abstraktion und Generalisierung der gebildeten Kategorien ein Teil der induktiven Inhaltsanalyse (vgl. Elo & Kyngäs 2008: 111), weshalb solch spezifische Kategorien kein Problem darstellen. Die inhaltliche Einordnung der einzelnen Kategorien durch ChatGPT erscheint in dieser Hinsicht von Nutzen, sodass darauffolgend in einem optionalen dritten Arbeitsschritt die Kategorien thematisch verfeinert und erneut auf das Sample oder gegebenenfalls auf ein weiteres, größeres Sample angewendet werden kann. Die allgemeine Performance von ChatGPT bei der induktiven Kategorienbildung scheint bei höheren Temperaturen besser zu sein. Während die Anzahl der Fehler und Unklarheiten etwas höher liegt als bei einer Temperatur von 0.5, konnten mehr übergeordnete Kategorien gebildet werden, ohne dabei viel Plausibilität einzubüßen. Eine zufälligere und kreativere Arbeitsweise kommt dem theoriegenerierenden, explorativen Ansatz der induktiven Inhaltsanalyse demnach mehr entgegen als eine konservativere.

Tabelle 1: Induktiv gebildete Kategorien bei einer Temperatureinstellung von 1.0

Kategorie	Im Codebuch?	Bemerkungen
1. Infragestellung des wissenschaftlichen Diskurses zum Klimawandel	-	-
Zweifel an wissenschaftlichem Konsens	Ja, UXWM	-
Klimawandel-Leugnung	Ja, CHNP	Unscharf
2. Kritik an den Maßnahmen zur Bekämpfung des Klimawandels	-	-
Kritik an unzureichenden Maßnahmen	-	-
Ablehnung der Maßnahmen zum Klimawandel	Ja, bspw. CMOB, PMRB	Unscharf
Pragmatische Kritik an Maßnahmen zum Klimawandel	Ja, PMRB	-
3. Kritik an der EU-Klimapolitik	-	-
Kritik an wirtschaftlicher Belastung der EU-Klimapolitik	Ja, EJNH	Im Gegensatz zum Codebuch hier auf die EU bezogen
Kritik an EU-Klimapolitik im Vergleich zu anderen Ländern	Ja, WANU	Im Gegensatz zum Codebuch hier auf die EU bezogen
Kritik an EU-Regulierungen im Bereich Klimaschutz	Ja, bspw. CMOB, PMRB	Im Gegensatz zum Codebuch hier auf die EU bezogen
Kritik an EU-Regulierungen im Bereich Landnutzung	-	-
Kritik an technokratischer EU-Klimapolitik	Ja, bspw. PIII, CAFM	Im Gegensatz zum Codebuch hier auf die EU bezogen
4. Forderung nach Nutzung erneuerbarer Energien	-	-
Befürwortung der Einführung von Zertifizierungs- und Informationsmechanismen	-	-
Unterstützung von Maßnahmen zum Klimaschutz	-	-
Unterstützung des Umwelt- und Gesundheitsschutzes	-	-
Unterstützung von Maßnahmen zum Klimawandel und Umweltschutz	-	-
5. Kritik an der Nutzung von Atomenergie	-	-
Kritik an der Abhängigkeit von Batterierohstoffen aus Ländern wie China	-	Passt nicht zur übergeordneten Kategorie
6. Förderung öffentlichen Verkehrs und Gütertransports per Bahn	-	-
Positive Auswirkungen der Städte auf den Klimawandel	-	-
Kritik an der Verflechtung von Politik und Wirtschaft	-	-
7. Verknüpfung von Waldsterben mit Klimawandel	-	-
Einfluss des Klimawandels auf Wälder	-	-
Regelungslücke bei der Zertifizierung von Fahrzeugen	-	-
Auswirkung des Emissionshandelssystems auf kleine und mittlere Unternehmen	Ja, CPFB	-
8. Ablehnung des Paris-Abkommens	-	-
Ablehnung der EU-Emissionshandelsrichtlinie	Ja, bspw. CPMM	Im Gegensatz zum Codebuch hier auf die EU bezogen
Ablehnung der Schaffung einer Marktstabilitätsreserve	-	-
Ablehnung der Klimaagenda	Ja, bspw. SGCA	-
Ablehnung von internationalen Klimaschutzabkommen und -initiativen	Ja, bspw. WGNS	-
Ablehnung von Maßnahmen zum Klimaschutz aufgrund von Geschlechterungleichheit	Ja, GPNE	-
Ablehnung von Maßnahmen zum Klimawandel	Ja, bspw. AHNP	Unscharf; sinngemäß im Codebuch
9. Bedenken bezüglich der Arbeitsplatzverluste in der Automobilindustrie	-	-

Tabelle 2 (Weiterführung): Induktiv gebildete Kategorien bei einer Temperatureinstellung von 1.0

Kategorie	Im Codebuch?	Bemerkungen
Dialog und kreative Lösungen mit den USA	-	-
Bedenken hinsichtlich der einseitigen Reduzierung von Emissionen	Ja, WANU	-
Befürchtungen hinsichtlich des Budgets und des Emissionszertifikate-Handelssystems	Ja, sinngemäß, bspw. CPMM	-
10. Kritik an unzureichenden Berechnungsmethoden	-	-
Kritik an finanzierten "Grünwaschung" von Unternehmen	-	-
Kritik an fehlender Klimazertifizierung	-	-
Kritik an der fehlenden Vorabmessung der Auswirkungen	Ja, NGIS, TETT	-
Kritik an mangelnder globaler Vereinbarung zur Emissionsreduktion	Ja, WANU	-
Kritik an vorgeschlagenen Maßnahmen zur Förderung von Elektromobilität	-	-
Kritik am Emissionshandelssystem	Ja, CPMM, CPFB	Unscharf
Kritik an unzureichender Datenbasis	Ja, NGIS, CMOU	-

Die Wiederholung der Arbeitsschritte bei einer Temperatureinstellung von 1.5 hat wiederum zu unbrauchbaren Ergebnissen geführt[11]. Der Ursache dafür kann in diesem Rahmen nicht nachgegangen werden, sie ist unklar; dem Output des Modells nach zu urteilen, ist ein Fehler auf Seiten der Server von OpenAI genauso denkbar, wie dass das Modell bei einer solchen Einstellung nicht in der Lage ist, die Aufgabenstellung adäquat umzusetzen.

5.3 Diskussion der Ergebnisse und Beantwortung der Forschungsfragen

Die vorliegende Arbeit untersucht die Eignung von ChatGPT zur Unterstützung bei der qualitativen Inhaltsanalyse in den Sozialwissenschaften. Dabei wurde sowohl die deduktive als auch die induktive Inhaltsanalyse nach Mayring (2000) berücksichtigt. Die Reliabilität der Kodierungsleistung, gemessen mit Krippendorfs Alpha, unterscheidet sich sehr stark, je nachdem wie zufällig das Modell arbeiten soll, was bei den GPT-Modellen über die Temperatureinstellung geregelt wird. Während die Konsistenz in einer konservativen Einstellung von 0.0 hoch ist, liegt sie für die Temperaturen 0.5 und 1.0 unter einem tolerierbaren Niveau. Nichtsdestotrotz übertreffen die Werte für Krippendorffs Alpha bei den Temperaturen 0.0 und 0.5 die einer ersten Kodierung durch menschliche Coder. Andererseits sind die Fehlerquoten bei der Zuweisung der korrekten Codes durch ChatGPT nicht nur zu hoch, sondern die Art der Fehler teilweise sehr gravierend. Es stellt sich dabei jedoch die Frage, welche Fehlerquote noch akzeptabel ist. Selbst bei der konservativsten Einstellung bleibt eine Fehlerquote von

[11] Dateien: *merged_categories_kleines_sample_15.txt*; *merged_categories_großes_sample_15.txt*

26,4%, jeder vierte Code wurde somit nicht korrekt zugewiesen. Der damit einhergehende Arbeitsaufwand, um die Ergebnisse zu sichten und zu überarbeiten, droht den generierten Nutzen somit zu übersteigen. Eine größere Rolle bei der deduktiven Kodierung von Textmaterial ist ChatGPT deshalb noch nicht zuzutrauen. Die Nutzung als zusätzlicher Coder, wie sie zum Beispiel Ziems et al. (2023: 17) vorschlagen, ist gegebenenfalls bei konservativer Temperatur möglich. Eine mehrfache Kodierung mit anschließendem Pooling der Ergebnisse, also einem Zusammenführen derselben in eine einzelne Kodierung (vgl. Reiss 2023: 8), ist in diesem Fall jedoch empfehlenswert. Ansonsten kann ChatGPT hier allenfalls als Ergänzung genutzt werden, um Textstellen zu finden, die menschlichen Codern möglicherweise entgangen sind. Auf eine menschliche Validierung der Qualität von ChatGPTs Output kann bei keiner Nutzung verzichtet werden. ChatGPTs Eignung zur Verwendung in der deduktiven Inhaltsanalyse ist somit beschränkt und ob sich die Nutzung lohnt, insbesondere mit Blick auf den zu betreibenden Aufwand bei der Programmierung und der Aufbereitung der Ergebnisse, sollte bei jedem Forschungsvorhaben abgewogen werden. Eine Beantwortung der Forschungsfrage bezüglich der Eignung von ChatGPT für die deduktiven Inhaltsanalyse ist somit zwar nicht vollends negativ zu beantworten, die Eignung des Modells ist zum jetzigen Zeitpunkt aber lediglich beschränkt vorhanden.

Bei der induktiven Kategorienbildung zeichnet sich ein anderes Bild. Der in dieser Arbeit durchgeführte zweiteilige Arbeitsprozess führt zu überzeugenden Ergebnissen. Während die Qualität der Kategorienbildung bei niedrigeren Temperaturen sehr gut ist, arbeitet ChatGPT bei einer Temperatur von 1.0 variantenreicher und bildet dementsprechend ein thematisch breiteres Feld ab. Die Ergebnisse bei einer Einstellung von 1.5 waren wiederum unbrauchbar. Die Generierung neuer Kategorien profitiert also bis zu einem gewissen Grad von einer kreativeren Arbeitsweise des Modells. Da eine händische Überprüfung und die Überarbeitung der Ergebnisse ohnehin nötig sind, um die Kategorien je nach Forschungsinteresse einzugrenzen, ist auch der niedrigen Fehlerquote leicht zu begegnen. Der Arbeitsaufwand wird insofern nicht negativ beeinflusst. Die Verwendung von ChatGPT zur Unterstützung einer induktiven Inhaltsanalyse ist somit empfehlenswert. LLMs sind offensichtlich in der Lage, große Mengen an Text schnell zu verarbeiten, dies jedoch auch in einer Qualität, die dem ersten Schritt einer induktiven Inhaltsanalyse gerecht wird.

5.4 Limitationen der Arbeit

Der Black-Box Charakter von ChatGPT und die Limitationen, die er mit sich bringt, treffen teilweise auch auf die vorliegende Arbeit zu. Eine Replikation der Ergebnisse der induktiven Kategorienbildung gestaltet sich bei diesen probabilistischen Modellen insbesondere bei höheren Temperatureinstellungen als schwierig, da sich die Outputs des Modells immer unterscheiden werden. Die Ergebnisse zur Reliabilität der Modelle wiederum spiegeln genau diese Zufälligkeit wider, weshalb sie replizierbar sind. Nichtsdestotrotz sind die Unsicherheiten bezüglich der Intransparenz und der Zukunft der Modelle nichts, was hier berücksichtigt werden könnte. So sind Überarbeitungen von mehreren GPT-3.5-Modellen genauso wie völlig neue Modelle wie GPT-4 angekündigt oder bereits Realität, während ältere Modelle regelmäßig eingestellt werden (vgl. OpenAI Platform o.D. c). Neue Modelle bringen selbstverständlich neue Eigenschaften mit sich, weshalb manche Ergebnisse dieser Arbeit nur als Momentaufnahme angesehen werden können.

Eine andere Limitation besteht in der Samplegröße der deduktiven Kodierung. 20 Texte eines Materialkorpus von 947 ist insofern möglicherweise problematisch, als dass nur knapp 2/3 der Codes überhaupt verwendet wurden. In dieser Hinsicht fehlt es also an Daten. Eine mögliche Folgestudie könnte hier mehr Material kodieren lassen. Während die Auswahl der Samplegröße aufgrund der Kosten- und Zeitimplikationen für die Expertenkodierung so gewählt wurde, unterstreicht sie gleichzeitig eine Limitation des Arbeitsprozesses. Die Samplegröße erschien für die Arbeit als gerade noch klein genug, um einen effizienten Workflow zu gewährleisten. Bei mindestens zehn Prompts oder mehr je Durchführung einer Schleife, die jedes Mal das Tokenlimit ausnutzen, sind während dieser Studie Time-Out-Fehler, Konnektivitätsprobleme und überlastete Server regelmäßig aufgetreten.

6. Fazit und Ausblick

Die meisten Forschungsvorhaben, die ChatGPTs Eignung für die qualitative Inhaltsanalyse untersucht haben, konzentrieren sich momentan auf die deduktive Form der Methode (u.a.: Gilardi et al 2023; Reiss 2023; Törnberg 2023a). Diese Arbeit beschäftigt sich ebenfalls mit dieser Frage und kann dazu die Schlussfolgerung beitragen, dass der Nutzen von ChatGPT in dieser Hinsicht noch eingeschränkt ist und eine Verwendung nur in kleinem Rahmen sinnvoll ist. Während die Konsistenz der Modelle zumindest bei konservativer Temperatureinstellung ausreichend ist und die des hier durchgeführten ersten Kodierungsdurchlauf der menschlichen Coder übertrifft, ist die

Fehlerquote bei der Zuweisung von Codes bereits ab einer Temperatur von 0.5 zu hoch. Bezüglich der Forschungsfrage nach der Eignung bei der deduktiven Kodierung von Textmaterial, ergibt sich somit ein uneindeutiges Bild; Forschende müssen den Nutzen dem Mehraufwand gegenüber somit genau abwägen. Für eine eindeutige Empfehlung sind die Fehlerquoten und teilweise auch die Konsistenz des Modells nicht gut genug. Ob eine Variation der Prompts hinsichtlich der Fehlerquote Verbesserungen mit sich bringt, ist eine Frage, die sich für weiterführende Untersuchungen anbietet. Das Format, in dem ChatGPT die Ergebnisse darstellt, ist wiederum praktikabel, sodass auf den hier verwendeten Prompts aufgebaut werden kann.

Darüber hinaus macht diese Arbeit jedoch einen ersten Schritt zur Untersuchung von ChatGPTs Möglichkeiten bei der induktiven Inhaltsanalyse, die sehr vielversprechend erscheinen. Während eine händische Kontrolle weiter nötig ist und einer Zeitersparnis, für die ChatGPT großes Potential verspricht, somit bisher keine große Bedeutung zukommt, spricht die Qualität der Ergebnisse für eine Verwendung beispielsweise bei der Materialsichtung oder als hochwertige Ergänzung der eigenen Kategorienbildung. Davon abgesehen, ist die Immersion des Forschenden in das Material eines der Charakteristika der qualitativen und insbesondere der induktiven Inhaltsanalyse (vgl. Elo & Kyngäs 2007: 109), weshalb Effizienz weniger das Ziel sein sollte als Effektivität, die mit ChatGPT gesteigert werden kann. Auch die Programmierung des Modells dürfte Laien vor keine allzu großen Schwierigkeiten stellen, zumal ChatGPT selbst dafür eine Hilfe sein kann. Die wichtigste Fähigkeit mit Blick auf LLMs, die Forschende für eine solche Analyse also mitbringen sollten, ist das Prompting. Der in Kapitel 4 vorgestellte, an der Fachliteratur orientierte Ansatz hat sich für die induktive Inhaltsanalyse als durchaus leistungsstark erwiesen. Alles in allem ist die zweite Forschungsfrage somit positiv zu beantworten, ChatGPT eignet sich bereits jetzt bei der Verwendung zur induktiven Kategorienbildung im Zuge einer qualitativen Inhaltsanalyse.

Bei Betrachtung der Ergebnisse dieser Arbeit darf nicht vernachlässigt werden, dass es sich nur um eine Momentaufnahme handeln kann. Das Feld der künstlichen Intelligenz und der LLMs befindet sich in einem Zustand rasanter, tiefgreifender Veränderungen. OpenAI veröffentlicht beispielsweise regelmäßig neue Updates, neue Versionen aktueller Modelle oder gänzlich neue Modelle, die sich unter anderem hinsichtlich ihrer Trainingsdaten oder auch der Anzahl der je Anfrage verfügbaren Tokens unterscheiden können (OpenAI Platform o.D. c). Mit Blick auf die großen Fortschritte der letzten Jahre und dem unter anderem in dieser Arbeit präsentierten Stand, dürfte es nur

eine Frage der Zeit sein, bis LLMs die Aufgaben einer qualitativen Inhaltsanalyse mit einer ausreichenden Qualität bearbeiten können.

Gewisse Risiken bestehen jedoch weiterhin: gemäß ihrer Black-Box-Eigenschaften herrscht teilweise auch immer Unklarheit über viele Unterschiede der neuen oder aktualisierten Modelle. Genauso können plötzliche Geschehnisse im Unternehmen oder dessen Umfeld Instabilität mit sich bringen, die potentiell auch Auswirkungen auf die Weiterentwicklung und Pflege der Modelle haben können. Ein Beispiel für solche Geschehnisse ist die Entlassung von Sam Altman, dem CEO von OpenAI, der unter Druck von der Belegschaft wenige Tage später wieder eingesetzt wurde (vgl. Der Spiegel 2023). Davon abgesehen birgt der freie Markt Risiken für die Unternehmen, die solche Modelle anbieten, und die sich negativ auf die Verfügbarkeit oder Qualität der Modelle auswirken können. Die Entwicklung von Opensource-Plattformen, die in der Forschung Anwendung finden können, ist daher von großer Wichtigkeit (vgl. Spirling 2023).

Neben einer solchen Entwicklung ist eine kontinuierliche Evaluation der Leistung und Verwendungsmöglichkeiten von LLMs in der Sozialforschung zukünftig unersetzlich. Zukünftige Forschungsvorhaben können die hier gemachten Erkenntnisse weiter vertiefen. Das Ziel für die deduktive Kodierung muss sein, die Fehlerquote zu reduzieren; Ansätze könnten der Prompt oder das Coding Framework sein, beispielsweise eine Verringerung der Kategorien, die pro Prompt untersucht werden. Bei der induktiven Kategorienbildung könnte in einem nächsten Schritt die Konsistenz der Outputs überprüft werden, um zu testen, ob das Zusammenlegen der in verschiedenen Durchführungen eines Prompts gebildeten Kategorien die thematische Bandbreite erhöht oder ob diese konstant bleibt. Auch könnten weitere Aspekte der qualitativen Inhaltsanalyse mit Blick auf Verwendungsmöglichkeiten von ChatGPT untersucht werden, wie zum Beispiel die Generalisierung der induktiv gebildeten Kategorien.

7. Literaturverzeichnis

Argyle, Lisa P./Ethan C. Busby/Nancy Fulda/Joshua R. Gubler/Christopher Rytting/David Wingate (2023): Out of One, Many: Using Language Models to Simulate Human Samples, in: *Political Analysis*, Oxford University Press, Bd. 31, Nr. 3, S. 337–351, [online] doi:10.1017/pan.2023.2.

Artificial intelligence: Threats and opportunities (2023): News European Parliament, [online] https://www.europarl.europa.eu/news/en/headlines/society/20200918STO87404/artificial-intelligence-threats-and-opportunities [abgerufen am 14.11.2023].

Bail, Christopher A. (2023): Can Generative AI Improve Social Science?, in: *SocArXiv*, [online] doi:10.31235/osf.io/rwtzs.

Barnett, Mike/William M. Ruhsam (1968): A natural language programming system for text processing, in: *IEEE Transactions on Engineering Writing and Speech*, Institute of Electrical and Electronics Engineers, Bd. 11, Nr. 2, S. 45–52, [online] doi:10.1109/tews.1968.4322334.

Berglund, Martin/Brink Van Der Merwe (2023): Formalizing BPE tokenization, in: *Electronic proceedings in theoretical computer science*, Open Publishing Association, Bd. 388, S. 16–27, [online] doi:10.4204/eptcs.388.4.

Borji, Ali (2023): A categorical archive of ChatGPT failures, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2302.03494.

Brown, T. B./Benjamin Mann/Nick Ryder/Melanie Subbiah/Jared Kaplan/Prafulla Dhariwal/Arvind Neelakantan/Pranav Shyam/Girish Sastry/Amanda Askell/Sandhini Agarwal/Ariel Herbert-Voss/Gretchen Krueger/Tom Henighan/Rewon Child/A. Ramesh/Daniel M. Ziegler/Jeffrey Wu/Clemens Winter/Christopher Hesse/Mark Chen/Eric J. Sigler/Mateusz Litwin/Scott Gray/Benjamin Chess/Jack Clark/Christopher Berner/Sam McCandlish/Alec Radford/Ilya Sutskever/Dario Amodei (2020): Language models are Few-Shot learners, in: *arXiv (Cornell University)*, Cornell University, [online] https://arxiv.org/pdf/2005.14165.pdf.

Chew, Rob/John Bollenbacher/Michael Wenger/Jessica Speer/Annice Kim (2023): LLM-Assisted Content Analysis: Using large language models to support deductive coding, in: *arXiv (Cornell University*), Cornell University, [online] doi:10.48550/arxiv.2306.14924.

Chung, Hyung Won/Lei Hou/Shayne Longpre/Barret Zoph/Yi Tay/William Fedus/Eric Li/Xuezhi Wang/Mostafa Dehghani/Siddhartha Brahma/Albert Webson/Shixiang Gu/Zhuyun Dai/Mirac Süzgün/Xinyun Chen/Aakanksha Chowdhery/Sharan Narang/Gaurav Mishra/Adams Yu/Vincent Zhao/Y. Huang/Andrew M. Dai/Hang Yu/Slav Petrov/Ed Chi/Jeff Dean/Jacob Devlin/Adam Roberts/Denny Zhou/Quoc V. Le/Jason Lee (2022): Scaling Instruction-Finetuned Language Models, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2210.11416.

Crompton, Helen/Diane Burke (2023): Artificial intelligence in Higher Education: the state of the field, in: *International Journal of Educational Technology in Higher Education*, Springer Nature, Bd. 20, Nr. 1, [online] doi:10.1186/s41239-023-00392-8.

DAIR.AI (o. D.): Elements of a prompt, Prompt Engineering Guide, [online] https://www.promptingguide.ai/introduction/elements [abgerufen am 23.11.2023].

Dergaa, Ismail/Karim Chamari/Piotr Żmijewski/Helmi Ben Saad (2023): From Human writing to Artificial intelligence generated text: Examining the prospects and potential threats of ChATGPT in academic writing, in: *Biology of Sport*, Termedia Publishing House, Bd. 40, Nr. 2, S. 615–622, [online] doi:10.5114/biolsport.2023.125623.

Der Spiegel (2023): Geschasster Chef Sam Altman kehrt zurück zu OpenAI, in: *DER SPIEGEL*, 22.11.2023, [online] https://www.spiegel.de/netzwelt/chatgpt-sam-altmann-nach-rauswurf-wieder-zurueck-zu-openai-a-a5311ccd-4edf-4107-8de1-060e8734fe61 [abgerufen am 26.11.2023]

Dwivedi, Yogesh K./Nir Kshetri/Laurie Hughes/Emma Slade/Anand Jeyaraj/Arpan Kumar Kar/Abdullah M. Baabdullah/Alex Koohang/Vishnupriya Raghavan/Manju Ahuja/Hanaa Albanna/Mousa Ahmad Albashrawi/Adil S. Al-Busaidi/Janarthanan Balakrishnan/Yves Barlette/Sriparna Basu/Indranil Bose/Laurence Brooks/Dimitrios Buhalis/Lemuria Carter/Soumyadeb Chowdhury/Tom Crick/Scott W. Cunningham/Gareth Davies/Robert M. Davison/Rahul Dé/Denis Dennehy/Yanqing Duan/Rameshwar Dubey/Rohita Dwivedi/John S. Edwards/Carlos Flavián/Robin Gauld/Varun Grover/Mei-Chih Hu/Marijn Janssen/Paul Jones/Iris A. Junglas/Sangeeta Khorana/Sascha Kraus/Kai R. Larsen/Paul L. Latreille/Sven Laumer/F. Tegwen Malik/Abbas Mardani/Marcello M. Mariani/Sunil Mithas/Emmanuel Mogaji/Jeretta Horn Nord/Siobhán O'Connor/Fevzi Okumuş/Margherita Pagani/Neeraj Pandey/Savvas Papagiannidis/Ilias O. Pappas/Nishith Pathak/Jan Pries-Heje/Ramakrishnan Raman/Nripendra P. Rana/Sven-Volker Rehm/Samuel Ribeiro-Navarrete/Alexander Richter/Frantz Rowe/Suprateek Sarker/Bernd Stahl/Manoj Kumar Tiwari/Wil Van Der Aalst/Viswanath Venkatesh/Giampaolo Viglia/Michael Wade/Paul Walton/Jochen Wirtz/Ryan Wright (2023): Opinion paper: "So what if ChaTGPT wrote it?" Multidisciplinary perspectives on opportunities, challenges and implications of Generative Conversational AI for research, practice and policy, in: *International Journal of Information Management*, Elsevier BV, Bd. 71, S. 102642, [online] doi:10.1016/j.ijinfomgt.2023.102642.

Elo, Satu/Helvi Kyngäs (2008): The Qualitative Content analysis process, in: *Journal of Advanced Nursing*, Wiley-Blackwell, Bd. 62, Nr. 1, S. 107–115, [online] doi:10.1111/j.1365-2648.2007.04569.x.

Escotet, Miguel Ángel (2023): The optimistic future of artificial intelligence in higher education, in: *PROSPECTS*, Springer Science+Business Media, [online] doi:10.1007/s11125-023-09642-z.

European Parliament (o. D.): MEPs: Directory, European Parliament, [online] https://www.europarl.europa.eu/meps/en/directory [abgerufen am 21.11.2023].

Fauzi, Fauzi/Laros Tuhuteru/Ferdinandus Sampe/Abu Muna Almaududi Ausat/Heliza Rahmania Hatta (2023): Analysing the role of CHATGPT in improving student productivity in higher education, in: *Journal on Education*, Universitas Pahlawan Tuanku Tambusai, Bd. 5, Nr. 4, S. 14886–14891, [online] doi:10.31004/joe.v5i4.2563.

Flick, Uwe (2023): *An introduction to qualitative research*, 7. Aufl., London, Vereinigtes Königreich: Sage Publications Limited.

Forchtner, Bernhard/Balša Lubarda (2022): Scepticisms and beyond? A comprehensive portrait of climate change communication by the far right in the European Parliament, in: *Environmental Politics, Taylor & Francis*, Bd. 32, Nr. 1, S. 43–68, [online] doi:10.1080/09644016.2022.2048556.

Gilardi, Fabrizio/Meysam Alizadeh/Maël Kubli (2023): ChatGPT outperforms crowd workers for text-annotation tasks, in: *Proceedings of the National Academy of Sciences of*

the United States of America, National Academy of Sciences, Bd. 120, Nr. 30, [online] doi:10.1073/pnas.2305016120.

Glaser, Noah (2023): Exploring the Potential of ChatGPT as an Educational Technology: An Emerging Technology report, in: *Technology, Knowledge, and Learning*, Springer Science+Business Media, Bd. 28, Nr. 4, S. 1945–1952, [online] doi:10.1007/s10758-023-09684-4.

Guterres, António (2023): Secretary-General's remarks to the Security Council on Artificial Intelligence, [online] https://www.un.org/sg/en/content/sg/statement/2023-07-18/secretary-generals-remarks-the-security-council-artificial-intelligence-bilingual-delivered-scroll-down-for-all-eng-lish?_gl=1*sacqcx*_ga*NTExNTU3Mzk0LjE2OTk3MDEzODc.*_ga_TK9BQL5X7Z*MTY5OTcwMTkxOC4xLjEuMTY5OTcwMzYwMS4wLjAuMA..*_ga_S5EKZKSB78*MTY5OTcwMjg5NC4xLjEuMTY5OTcwMzYwMS42MC4wLjA.

Haque, Mubin Ul/Isuru Dharmadasa/Zarrin Tasnim Sworna/Roshan N. Rajapakse/Hassan Ahmad (2022): „I think this is the most disruptive technology": Exploring sentiments of ChatGPT early adopters using Twitter data, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2212.05856.

Harrison, John (2022): RSelenium: R Bindings for 'Selenium WebDriver', R package version 1.7.9, [online] https://CRAN.R-project.org/package=RSelenium

Hayes, A. (2023). "Conversing" with Qualitative Data: Enhancing Qualitative Research through Large Language Models (LLMs) [online]. Available from: osf.io/preprints/socarxiv/yms8p.

He, Zhonghu/Chuhao Wu/Jingyi Xie/ChanMin Kim/John M. Carroll (2023): QualiGPT: GPT as an easy-to-use tool for qualitative coding, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2310.07061.

Hsieh, Hsiu Fang/Sarah E. Shannon (2005): Three approaches to qualitative content analysis, in: *Qualitative Health Research*, SAGE Publishing, Bd. 15, Nr. 9, S. 1277–1288, [online] doi:10.1177/1049732305276687.

Iyer, Srinivasan/Xi Victoria Lin/Ramakanth Pasunuru/Todor Mihaylov/Daniel Simig/Ping Yu/Kurt Shuster/Tianlu Wang/Qing Liu/Punit Singh Koura/Xian Li/Brian O'Horo/Gabriel Pereyra/Jeff Wang/Christopher Dewan/Aslı Çelikyılmaz/Luke Zettlemoyer/Ves Stoyanov (2022): OPT-IML: Scaling Language Model instruction Meta Learning through the lens of Generalization, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2212.12017.

Kaddour, Jean/Joshua S. Harris/Maximilian Mozes/Herbie Bradley/Roberta Raileanu/Robert McHardy (2023): Challenges and applications of large language models, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2307.10169.

Khlaif, Zuheir N./Allam Mousa/Muayad Kamal Hattab/Jamil Itmazi/A.N. Hassan/Mageswaran Sanmugam/AbdulKarem Ayyoub (2023): The potential and concerns of using artificial intelligence in scientific research: the case of ChatGPT (Preprint), in: *JMIR medical education*, JMIR Publications, Bd. 9, S. e47049, [online] doi:10.2196/47049.

Kozina, Slavica/Martin Kowalski/Mirela Vlastelica/Tonći Mastelić/Josip Anđelo Borovac (2019): Traumatic memory of one's son gone missing in war: Content analysis using Krippendorff's Alpha, in: *SAGE Open*, SAGE Publishing, [online] doi:10.1177/2158244019839627.

Krauss, Steven Eric (2015): Research Paradigms and Meaning Making: A primer, in: *The qualitative report*, Nova Southeastern University, [online] doi:10.46743/2160-3715/2005.1831.

Krippendorff, Klaus (2004): Measuring the reliability of qualitative text analysis data, in: *Quality & Quantity*, Bd. 38, Nr. 6, S. 787–800, [online] doi:10.1007/s11135-004-8107-7.

Kucharavy, Andrei/Z. M. Schillaci/Loïc Maréchal/Maxime Würsch/Ljiljana Dolamic/Remi Sabonnadiere/Dimitri Percia David/A. Mermoud/Vincent Lenders (2023): Fundamentals of Generative large language Models and Perspectives in Cyber-Defense, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2303.12132.

Lu, Yao/Max Bartolo/Alastair Moore/Sebastian Riedel/Pontus Stenetorp (2022): Fantastically ordered prompts and where to find them: Overcoming Few-Shot Prompt order sensitivity, in: *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, [online] doi:10.18653/v1/2022.acl-long.556.

Lyons, John (1991): *Natural language and universal grammar*, [online] doi:10.1017/cbo9781139165877.

Mayring, Philipp (2000). Qualitative Inhaltsanalyse [28 Absätze]. *Forum Qualitative Sozialforschung/ Forum: Qualitative Social Research*, 1(2), Art. 20, http://nbn-resolving.de/urn:nbn:de:0114-fqs0002204.

O'Connor, Clíodhna/Hélène Joffe (2020): Intercoder reliability in Qualitative Research: Debates and practical guidelines, in: *International journal of qualitative methods*, SAGE Publishing, Bd. 19, S. 160940691989922, [online] doi:10.1177/1609406919899220.

OpenAI Platform (o. D. a): OpenAI, [online] https://platform.openai.com/docs/introduction/key-concepts [abgerufen am 10.11.2023].

OpenAI Platform (o. D. b): [online] https://platform.openai.com/docs/libraries/python-library [abgerufen am 10.11.2023].

OpenAI Platform (o. D. c): [online] https://platform.openai.com/docs/libraries/python-library [abgerufen am 10.11.2023].

Paaß, Gerhard/Sven Giesselbach (2023): *Foundation models for natural language processing*, Artificial intelligence: Foundations, theory, and algorithms, [online] doi:10.1007/978-3-031-23190-2.

Poldrack, Russell A./Tianlan Lu/Gašper Beguš (2023): AI-assisted Coding: Experiments with GPT-4, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2304.13187.

Rahmstorf, Stefan (2004): The climate sceptics, in: Munich Re (Hrsg.), *Weather catastrophes and climate change - Is there still hope for us?*, pg-verlag, S. 76–83.

Reiss, Michael (2023): Testing the reliability of ChatGPT for text annotation and Classification: A cautionary remark, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2304.11085.

Rietz, Tim/Alexander Maedche (2021): Cody: An AI-Based System to Semi-Automate Coding for Qualitative Research, in: *In Proceedings of the 2021 CHI Conference on*

Human Factors in Computing Systems (CHI '21). Association for Computing Machinery, New York, NY, USA, S. 1–14, [online] doi:10.1145/3411764.3445591.

Rogers, Everett M./Horst D. Simon/Schuster (2003): *Diffusion of Innovations*, 5. Aufl., The Free Press.

Salah, Mohammed/Hussam Al Halbusi/Fadi Abdelfattah (2023): May the force of text data analysis be with you: Unleashing the power of Generative AI for social psychology research, in: *Computers in Human Behavior Artificial Humans*, Elsevier BV, Bd. 1, Nr. 2, S. 100006, [online] doi:10.1016/j.chbah.2023.100006.

Salewski, Leonard/Stephan Alaniz/Isabel Rio-Torto/Eric Schulz/Zeynep Akata (2023): In-Context impersonation reveals large language models' strengths and biases, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2305.14930.

Salleh, Hamidah M. (2023): Errors of commission and omission in Artificial intelligence: Contextual biases and voids of ChatGPT as a Research assistant, in: *Digital Economy and Sustainable Development*, Springer Science+Business Media, Bd. 1, Nr. 1, [online] doi:10.1007/s44265-023-00015-0.

Santurkar, Shibani/Esin Durmus/Faisal Ladhak/Cinoo Lee/Percy Liang/Tatsunori Hashimoto (2023): Whose opinions do language models reflect?, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2303.17548.

Schreier, Margrit (2012): *Qualitative content analysis in practice*. London: SAGE Publications Ltd.

Sennrich, Rico/Barry Haddow/Alexandra Birch (2016): Neural Machine Translation of Rare Words with Subword Units, in: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, S. 1715–1725, [online] doi:10.18653/v1/p16-1162.

Spirling, Arthur (2023): Why open-source generative AI models are an ethical way forward for science, in: *Nature*, Nature Portfolio, Bd. 616, Nr. 7957, S. 413, [online] doi:10.1038/d41586-023-01295-4.

Strübing, J. 2018. *Qualitative Sozialforschung: Eine komprimierte Einführung*. Berlin, Boston: De Gruyter Oldenbourg. https://doi.org/10.1515/9783110529920

Tai, Robert H./L. R. Bentley/Xin Xia/Jason Sitt/Sarah C. Fankhauser/Ana M. Chicas-Mosier/Brian D. Monteith (2023): Use of large language models to aid analysis of textual data, in: *bioRxiv (Cold Spring Harbor Laboratory)*, Cold Spring Harbor Laboratory, [online] doi:10.1101/2023.07.17.549361.

Törnberg, Petter (2023a): ChatGPT-4 outperforms experts and crowd workers in annotating political Twitter messages with Zero-Shot learning, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2304.06588.

Törnberg, Petter (2023b): ChatGPT-4 outperforms experts and crowd workers in annotating political Twitter messages with Zero-Shot learning, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2304.06588.

Van Dis, Eva A.M./Johan Bollen/Willem Zuidema/Robert Van Rooij/Claudi Bockting (2023): ChatGPT: Five priorities for Research, in: *Nature*, Nature Portfolio, Bd. 614, Nr. 7947, S. 224–226, [online] doi:10.1038/d41586-023-00288-7.

Van Rensburg, Willem (2015): Climate change scepticism, in: *SAGE Open*, SAGE Publishing, Bd. 5, Nr. 2, S. 215824401557972, [online] doi:10.1177/2158244015579723.

Vaswani, Ashish/Noam Shazeer/Niki Parmar/Jakob Uszkoreit/Llion Jones/Aidan N. Gomez/Łukasz Kaiser/Illia Polosukhin (2017): Attention is all you need, in: *arXiv (Cornell University)*, Cornell University, Bd. 30, S. 5998–6008, [online] https://arxiv.org/pdf/1706.03762v5.

Wang, Zengzhi/Qiming Xie/Zixiang Ding/Yong Feng/Rui Xia (2023): Is ChatGPT a good sentiment analyzer? A preliminary study, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2304.04339.

Wickham, Hadley (2021): rvest: Easily Harvest (Scrape) Web Pages, R package version 1.0.2, [online] https://CRAN.R-project.org/package=rvest

Xiao, Ziang/Xingdi Yuan/Q. Vera Liao/Rania Abdelghani/Pierre-Yves Oudeyer (2023): Supporting Qualitative Analysis with Large Language Models: Combining Codebook with GPT-3 for Deductive Coding, in: *28th International Conference on Intelligent User Interfaces (IUI '23 Companion), March 27–31, 2023, Sydney, NSW, Australia*, S. 75–78, [online] doi:10.1145/3581754.3584136.

Zamfirescu-Pereira, J. D./Richmond Y. Wong/Bjoern Hartmann/Qian Yang (2023): Why Johnny Can't Prompt: How Non-AI Experts Try (and Fail) to Design LLM Prompts, in: *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems (CHI '23), April 23–28, 2023, Hamburg, Germany*, [online] doi:10.1145/3544548.3581388.

Zhang, He/Chuhao Wu/Jingyi Xie/ChanMin Kim/John M. Carroll (2023): QualiGPT: GPT as an easy-to-use tool for qualitative coding, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2310.07061.

Zhao, Bo (2022): Web Scraping, Laurie A. Schintler/Connie L. McNeely (Hrsg.), Encyclopedia of Big Data, Cham, Schweiz: Springer Nature.

Zhou, Chuangbing/Qian Li/Chen Li/Yuanyuan Wang/Yixin Liu/Guangjing Wang/Kai Zhang/Jin Cheng/Qiben Yan/Lei He/Hao Peng/Jianxin Li/Wei Jia/Ziwei Liu/Pengtao Xie/Caiming Xiong/Jian Pei/Philip S. Yu/Lichao Sun (2023): A comprehensive survey on pretrained foundation Models: A History from BERT to ChaTGPT, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2302.09419.

Ziems, Caleb/William A. Held/Omar Ahmed Shaikh/Jiaao Chen/Z. Zhang/Diyi Yang (2023): Can large language models transform computational social science?, in: *arXiv (Cornell University)*, Cornell University, [online] doi:10.48550/arxiv.2305.03514.

8. Versicherung an Eides statt

Hiermit versichere ich an Eides statt, dass ich diese Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Außerdem versichere ich, dass ich die allgemeinen Prinzipien wissenschaftlicher Arbeit und Veröffentlichung, wie sie in den Leitlinien guter wissenschaftlicher Praxis der Carl von Ossietzky Universität Oldenburg festgelegt sind, befolgt habe.

Datum & Unterschrift

27.11.2023,